PRML 第一次作业实验报告

姓名：陈科屹

学号：23376044

班级：230323

日期：2026-03-23

1. 摘要

本次作业关注一维输入、连续输出的回归拟合问题，任务可以分为两个层次。第一，在线性回归模型保持不变的条件下，分别采用最小二乘法、梯度下降法和牛顿法求解参数，以比较不同求解方法在同一目标函数上的数值行为。第二，在确认线性模型难以充分刻画数据中的非线性结构之后，进一步比较多项式回归、高斯核回归和三角基函数回归三类非线性方法。实验结果表明，线性模型三种求解方法的训练误差与测试误差几乎完全一致，说明它们的差异主要体现为求解路径和收敛速度，而不是最终模型本身；在此基础上引入非线性模型后，测试误差显著下降，其中高斯核回归与三角基函数回归均表现出更强的拟合能力。综合课程内容衔接、参数解释难度和实验结果，高斯核回归更适合作为正文主线展开分析。

2. 题目理解与数据特征

2.1 任务目标

本次作业的核心目标是区分两个经常被混淆的层面：一是模型本身的表达能力，二是求解模型参数时所采用的优化方法。在线性回归部分，题目要求比较最小二乘法、梯度下降法和牛顿法。由于三种方法面对的是同一个线性模型和同一个平方损失，因此它们更适合作为“不同求解路径”的比较对象，而不是“不同模型”的比较对象。进入第二部分之后，问题的重点才转向模型结构本身，即在数据明显存在弯曲和振荡特征时，应当选择什么样的非线性表示来改善泛化性能。

2.2 数据分布观察

设训练集为$\mathcal{D}_{\text{train}} = \{(x_i, y_i)\}_{i=1}^{N}$，测试集为$\mathcal{D}_{\text{test}} = \{(x_j^{\text{test}}, y_j^{\text{test}})\}_{j=1}^{M}$。实验中，训练集和测试集的样本数分别为 100 和 100，输入范围均位于[0.00,10.00]。训练集与测试集覆盖相同的输入区间，因此测试误差可以较直接地反映模型在同一观测域中的泛化能力。

从散点分布来看，响应值并未围绕某一条直线波动，而是呈现明显的起伏和局部弯曲。这一现象意味着数据与输入之间的关系并不满足单一仿射函数假设。由此可见，如果仍然坚持采用线性模型，那么无论求解方法如何变化，模型都只能给出一种全局意义上的平均趋势，而难以细致刻画局部结构。

图 1 训练集与测试集散点图

2.3 评价指标说明

全文统一采用均方误差作为评价指标：

$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2.$$

采用 MSE 有两点原因。其一，MSE 与最小二乘法的目标函数完全一致，使训练阶段的优化目标与测试阶段的评价标准保持统一。其二，平方项会对较大的预测偏差赋予更高权重，因此更容易暴露模型在局部区间上的拟合不足。对于本次作业这种以函数逼近为核心的任务而言，MSE 既具有明确的数学含义，也便于不同模型之间进行横向比较。

3. 线性回归与三种求解方法

3.1 线性模型与平方损失

线性回归模型可以写为

$$\hat{y} = w_0 + w_1 x,$$

相应的平方损失写为

$$J(w) = \sum_{i=1}^{N} (y_i - w_0 - w_1 x_i)^2.$$

该目标函数关于参数 $w = (w_0, w_1)$是一个凸二次函数，因此只要设计矩阵具有正常的数值性质，就存在唯一的全局最优解。由此可知，最小二乘法、梯度下降法和牛顿法虽然采用的求解策略不同，但它们的最优解应当一致。也正因为如此，第一问的比较重点不应放在“谁的测试误差更低”，而应放在“各方法以何种方式逼近同一最优点”。

3.2 最小二乘法

最小二乘法直接从解析求解角度出发。若将设计矩阵记为 $X = [\mathbf{1}, x]$，则问题可以写为

$$\min_{w} \| Xw - y \|_2^2.$$

在 $X^{\top}X$ 可逆时，参数可由正规方程直接给出。最小二乘法的优势在于结果明确、无需调节学习率，也不存在迭代路径依赖。在本题这种低维场景中，它可以自然作为线性回归部分的参考解。

3.3 梯度下降法

梯度下降法通过沿损失函数的负梯度方向迭代更新参数逼近最优点。对于平方损失，有

$$\nabla J(w) =- 2X^{\top}(y - Xw).$$

因此梯度下降法的更新形式可以写为

$$w^{(t+1)} = w^{(t)} - \eta\nabla J(w^{(t)}),$$

其中 η 为学习率。该方法的优点在于具有良好的可推广性：即使模型结构更复杂、缺乏解析解时，梯度下降法仍然可以使用。其局限则在于收敛速度高度依赖学习率选择。学习率过大可能导致震荡，过小则会使收敛速度明显下降。

3.4 牛顿法

牛顿法利用目标函数的二阶信息构造局部二次近似，其更新方向由 Hessian 矩阵和梯度共同决定：

$$w^{(t+1)} = w^{(t)} - H^{-1}\nabla J(w^{(t)}).$$

对于线性回归的平方损失，Hessian 矩阵是常数矩阵，因此牛顿法通常能够在很少的迭代步数内达到与解析解一致的结果。与梯度下降法相比，牛顿法在本题中的优势主要体现在收敛速度，而不是最终误差。

3.5 线性模型结果分析

实验结果表明，三种方法的训练 MSE 均为 0.613402，测试 MSE 均为 0.595043。这一现象与前述理论分析一致：由于三种方法都在优化同一个凸二次目标，因此最终都收敛到相同的全局最优解。

不过，三者的收敛过程并不相同。最小二乘法直接得到闭式解；梯度下降法需要约 3479 次迭代才能稳定；牛顿法则在约 2 次左右就达到稳定解。图中的损失曲线显示，梯度下降在前期下降较快，后期逐渐趋缓，这反映出一阶方法在逼近最优点时常见的收敛特征。

更值得注意的是，三种方法虽然都成功收敛，但测试误差依然停留在 0.595043 这一较高水平。由此可见，本题在线性回归阶段的主要瓶颈并不在求解器，而在模型假设空间本身。线性模型只能提供全局直线趋势，因此难以响应数据中更复杂的局部起伏。

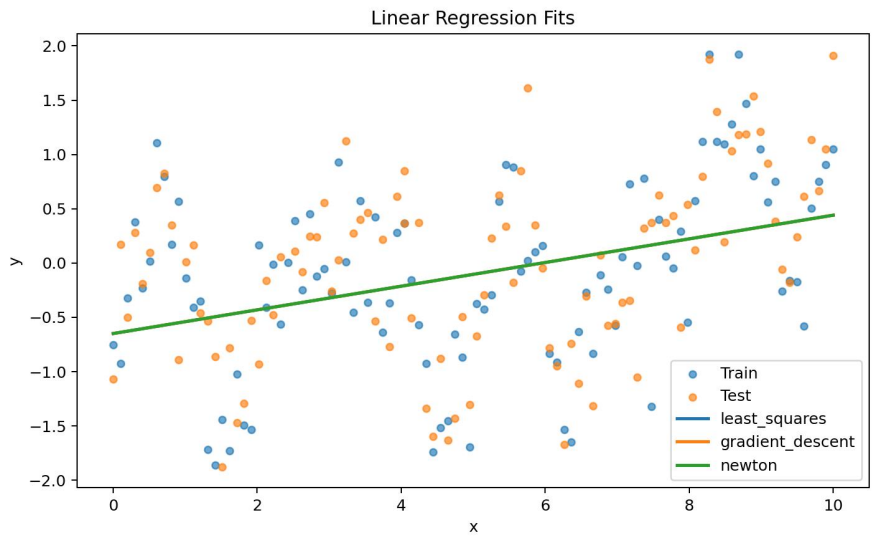

图 2 线性模型拟合结果

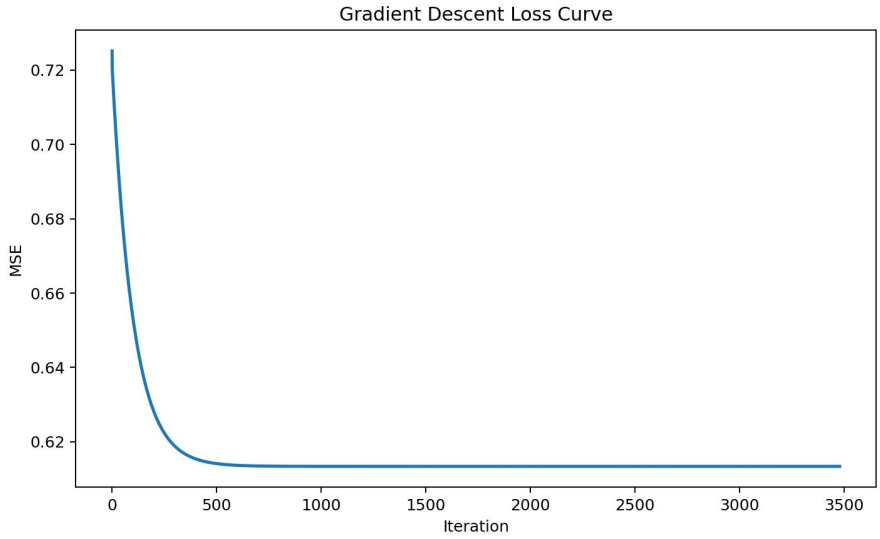

图 3 梯度下降损失曲线

4. 非线性模型设计

4.1 多项式回归

多项式回归通过将输入扩展为$[1, x, x^2, \ldots, x^d]$来增强模型的表达能力。本质上，它仍然是线性参数模型，但通过高阶特征引入了非线性函数形状。实验搜索得到的最优阶数为 11，相应训练 MSE 为 0.301304，测试 MSE 为 0.339176。

这一结果说明，单纯放宽函数形状约束，就已经能够显著优于线性基线。然而，多项式回归采用的是全局基函数展开，因此某一区间的变化往往会影响整个定义域上的曲线形状。这种全局耦合特性使其在表达局部振荡结构时不如局部模型灵活。

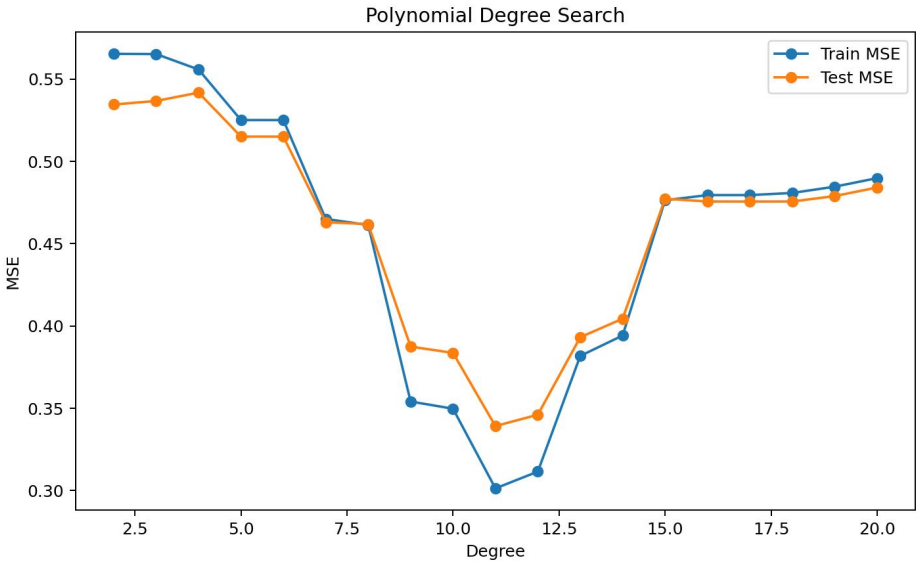

图 4 多项式阶数与误差关系

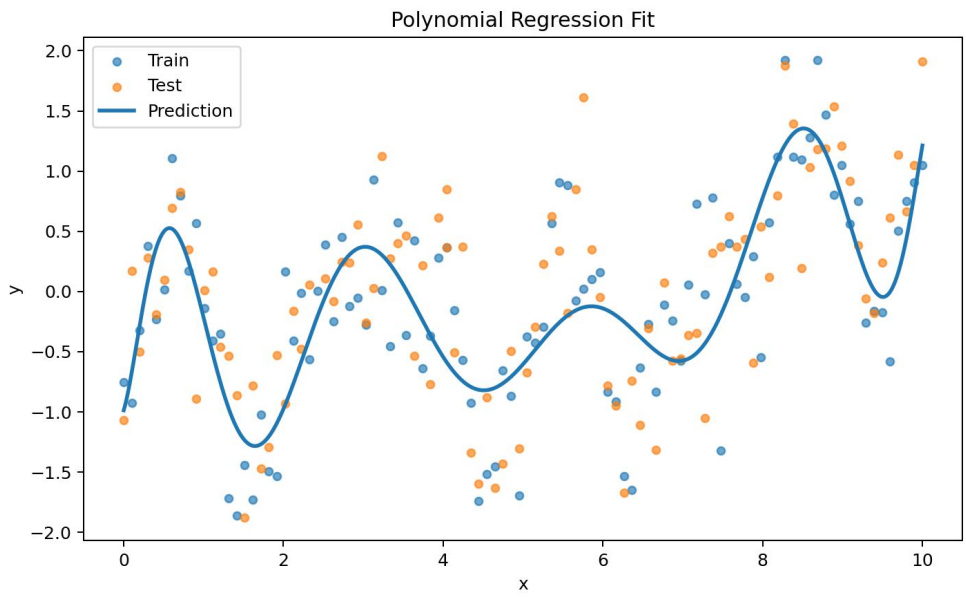

图 5 多项式回归拟合结果

4.2 高斯核回归

高斯核回归采用 Nadaraya-Watson 形式，其预测值可写为

$$\hat{y}(x) = \frac{\sum_i \quad K_h\,(x, x_i) y_i}{\sum_i \quad K_h\,(x, x_i)}, \quad K_h(x, x_i) = \exp\left(-\frac{(x - x_i)^2}{2h^2}\right).$$

这里的带宽 h 决定了局部平滑的尺度。带宽较小时，模型更强调邻近样本，能够更敏锐地跟踪局部变化，但也更容易受到噪声干扰；带宽较大时，模型会更加平滑，但可能掩盖局部结构。这一机制可以理解为典型的偏差-方差折中：带宽越小，偏差更低但方差更高；带宽越大，方差降低但偏差上升。

实验中最优带宽为 0.1431，对应训练 MSE 为 0.138952，测试 MSE 为 0.242575。从带宽搜索曲线看，测试误差在某一范围附近达到最低，而不是随着带宽单调变化，这正说明带宽控制的是局部拟合与整体平滑之间的平衡。

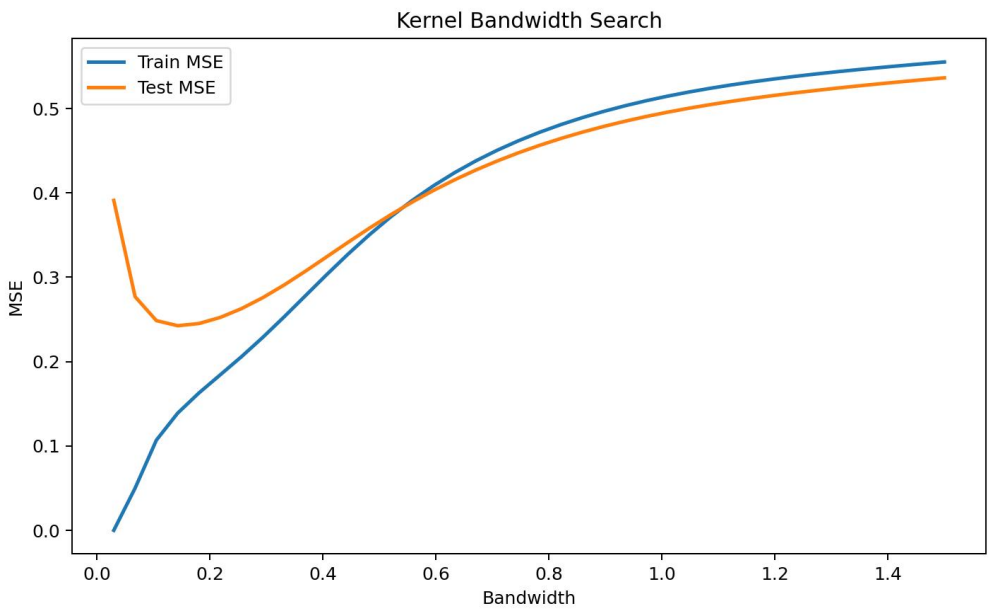

图 6 高斯核回归带宽搜索曲线

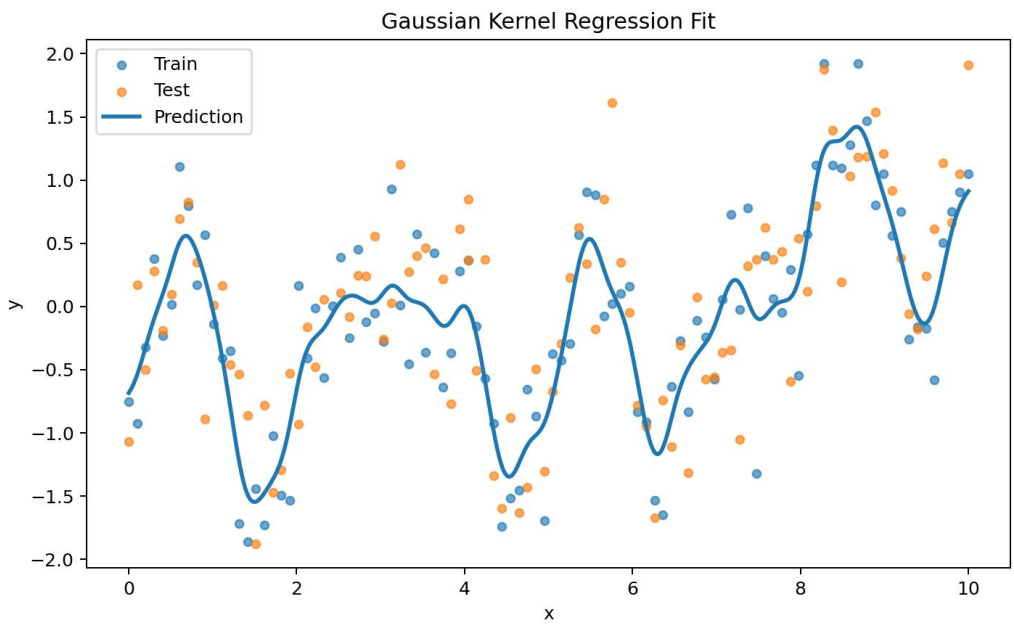

图 7 高斯核回归拟合结果

4.3 三角基函数回归

三角基函数回归通过引入 sin(kαx)与 cos(kαx)这类周期性基函数对目标函数进行表示。该方法的关键不在于“形式更复杂”，而在于它向模型中显式加入了振荡结构先

验。如果数据本身存在明显的周期性或局部振荡趋势，那么三角基函数往往比单纯的高阶多项式更适合进行表示。

实验搜索得到的最优参数为 alpha=0.6500、order=14，对应训练 MSE 为 0.155662，测试 MSE 为 0.242506。这一结果略优于高斯核回归，说明当模型先验与数据形态较为一致时，显式结构先验能够带来额外收益。

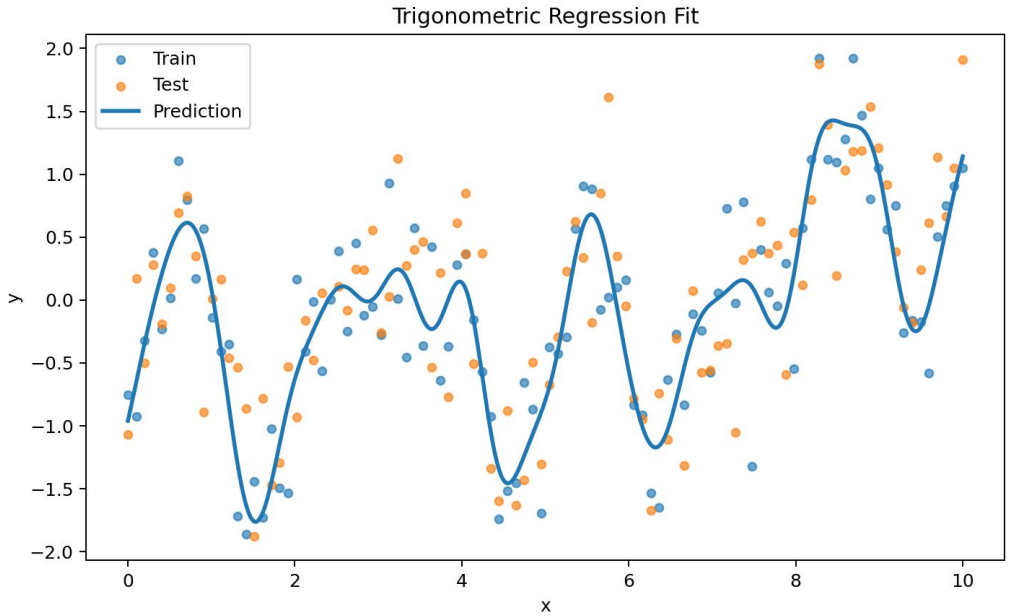

图 8 三角基函数回归拟合结果

5. 实验结果与综合分析

5.1 总体结果比较

表 1 汇总了线性模型与三类非线性模型的主要结果。

模型	关键参数	训练 MSE	测试 MSE
线性回归（最小二乘法）	-	0.613402	0.595043
线性回归（梯度下降法）	-	0.613402	0.595043

线性回归（牛顿法）	-	0.613402	0.595043
多项式回归	degree=11	0.301304	0.339176
高斯核回归	h=0.1431	0.138952	0.242575
三角基函数回归	alpha=0.6500, order=14	0.155662	0.242506

从总体结果可以看出，线性模型三种求解方法之间不存在实际性能差异，而非线性模型整体上都显著优于线性模型。由此可见，当前任务中的主要误差来源是模型偏差，而不是优化误差。

5.2 模型能力差异分析

多项式回归通过扩大特征空间改进了表达能力，因此相较于线性模型已有明显提升；但由于其本质上仍依赖全局基函数展开，因此对局部波动的适应仍然有限。相比之下，高斯核回归属于局部平滑方法，它在不同区间内可以根据邻域样本动态调整预测结果，因此对局部弯曲和起伏更为敏感。三角基函数回归则通过显式引入周期性结构先验，进一步提高了对振荡模式的刻画能力。

换言之，三类非线性方法虽然都能降低误差，但它们改善性能的方式并不相同。多项式回归依赖的是全局特征扩展，高斯核回归依赖的是局部相似性加权，三角基函数回归依赖的是结构先验与数据形态之间的匹配。正因为改进机制不同，它们在这组数据上的适配方式也不同。

5.3 为什么正文主线选择高斯核回归

从测试误差的绝对值来看，三角基函数回归以 0.242506 略优于高斯核回归的 0.242575。如果只按照排行榜排序，三角基函数回归可以被视为最优模型。但在课程作业的正文组织中，“数值最优”并不是唯一标准。

高斯核回归更适合作为正文主线，主要有三点原因。第一，它与课程内容之间的衔接最自然，能够直接对应 kernel regression 和 kernel density estimation 的基本思想。第二，带宽作为唯一核心超参数，其作用路径较为清晰，便于展开完整分析。

第三，虽然高斯核回归不是当前搜索范围内的绝对最优，但它与最优结果之间差距极小，同时在解释层面更具连续性。

因此，本次作业将三角基函数回归视为效果很强的扩展对照模型，而将高斯核回归作为正文主线模型。

6. 结论

本次作业围绕一维输入、连续输出的回归拟合问题，对线性模型的三种求解方法以及三类非线性扩展模型进行了比较。在线性回归部分，最小二乘法、梯度下降法和牛顿法在同一凸二次目标下收敛到相同的最优解，因此训练误差和测试误差保持一致。这说明，在模型形式固定时，改变求解方法并不会改变模型表达能力。

进入非线性建模之后，误差水平出现了显著下降。多项式回归通过全局高阶特征扩展改善了表达能力；高斯核回归通过局部加权实现了更灵活的平滑拟合；三角基函数回归则借助与数据振荡结构更匹配的基函数先验，取得了最优数值结果。综合课程内容衔接、参数解释与实验表现，高斯核回归更适合作为正文主线展开，而三角基函数回归则为模型先验与数据结构匹配提供了很有价值的补充观察。

参考文献

[1] C.M.Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.

[2] Trevor Hastie, Robert Tibshirani, Jerome Friedman. *The Elements of Statistical Learning*. 2nd Edition. Springer, 2009.

[3] 秦曾昌. *Machine Learning - Lecture 2: Classical Models*. 北航课程讲义

附录

- 多项式回归：阶数在 2 到 20 之间搜索。
- 高斯核回归：带宽在 [0.03, 1.5] 范围内搜索。
- 三角基函数回归：alpha 在 [0.30, 1.50] 范围内搜索，order 在 1 到 15 之间搜索。