3D Make-Moons 数据上的分类方法比较与分析

姓名：陈科屹

学号：23376044

2026 年 4 月 6 日

一. 摘要

围绕课程作业中的 3D Make-Moons 二分类任务，本次实验对 Decision Tree、AdaBoost + Decision Tree 以及四种核函数下的 SVM 进行比较。考虑到题目示例函数实际返回 $2 \times$ n_samples 个样本，而题面要求训练集和测试集总数分别为 1000 和 500，本文以题面文字为准，将训练集设为每类 500 个样本、测试集设为每类 250 个样本，噪声标准差统一为 0.2。

为保证结论具有可比性，所有模型均采用 5 折交叉验证进行超参数搜索，并在最优参数下补充 10 组随机数据的稳健性检验。固定随机种子时，多项式核 SVM 的测试准确率为 97.8%，略高于 RBF 核 SVM 与 AdaBoost 的 97.2%；Decision Tree 为 93.4%，线性核与 Sigmoid 核分别为 67.2% 和 83.6%。结果表明，3D 数据的判别边界具有明显的非线性特征，但整体形态连续且平滑，因此具备平滑曲面表达能力的核方法更适合该任务。单独用 Decision Tree 虽可获得较高训练精度，但轴对齐切分带来的过拟合更为明显；AdaBoost 在一定程度上缓解了这一问题。

二. 任务理解与实验目标

本次作业要求基于题目给定的 3D 数据生成方式，对 Decision Tree、AdaBoost + Decision Tree 和 SVM 的分类性能进行比较，并结合数据特征解释

结果差异。实验目标不仅是给出准确率排序，更重要的是分析模型边界形式与数据几何结构之间的对应关系。

该数据集的两类样本在三维空间中呈交错分布的弯曲轨迹，整体上并非线性可分。对于此类数据，若模型只能给出单一线性分隔面，边界能力通常不足；若能够形成连续的非线性曲面，则更可能贴合样本主结构。基于这一点，Decision Tree、AdaBoost 和不同核函数 SVM 的比较具有较强的代表性。

三. 数据集与预处理

题目给出的数据生成形式如下：

$$x = 1.5\cos t, \quad y = \sin t, \quad z = \sin(2t),$$

并构造另一类样本

$$(-x, y-1, -z),$$

随后在三维坐标上叠加高斯噪声。由此得到的两类样本在空间中形成一对错位分布的类似于弯月结构，局部区域彼此接近，但整体走势存在明显差异，因此线性分类器难以在全局范围内给出有效分隔。

需要说明的是，题目中的示例函数名为 make_moons_3d(n_samples=...)，但函数内部会分别生成两类数据并拼接，实际返回的样本总数为 2×n_samples。为满足“训练集 1000、测试集 500”的文字要求，本文将 n_samples 解释为每类样本数，即训练集使用每类 500 个样本，测试集使用每类 250 个样本。该处理方式与题面约束一致，也便于后续比较。

预处理方面，Decision Tree 与 AdaBoost 未进行标准化，因为树模型对特征尺度并不敏感；SVM 在训练前统一加入 StandardScaler，以避免某一维量纲主导核函数计算。整体设置保持克制，尽量不引入与题目目标无关的额外处理。

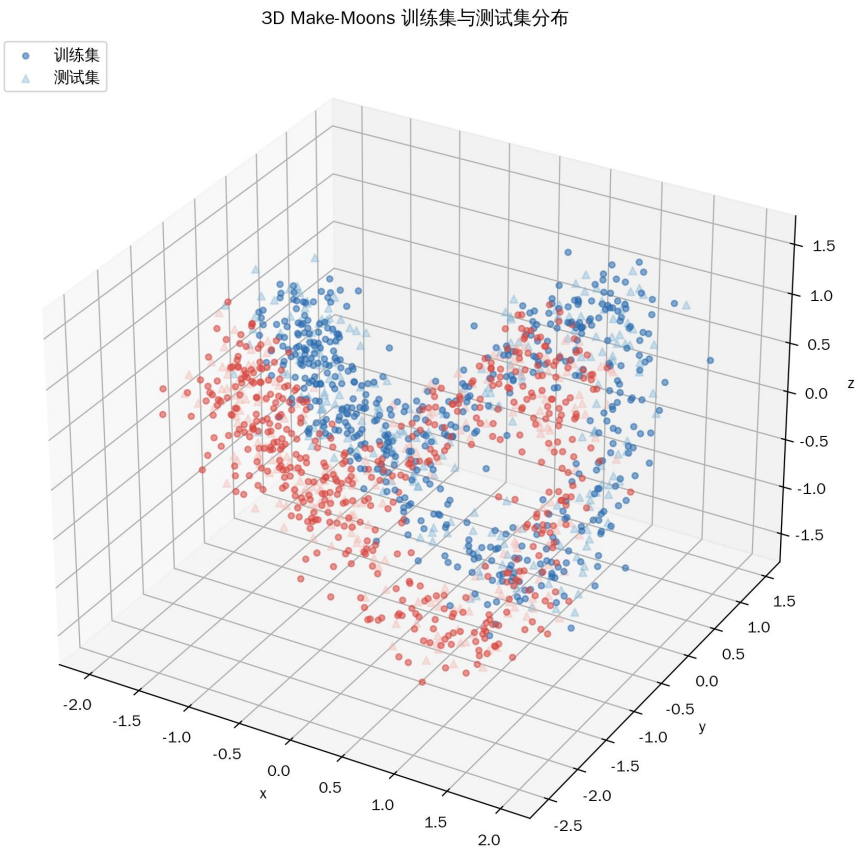

图 1 训练集与测试集在三维空间中的分布。

图 1 显示，训练集与测试集服从同一分布，测试样本仅在数量上更为稀疏。数据整体呈现连续、平滑且显著非线性的几何形态，这一特征构成了后续模型比较的主要背景。

四. 模型与实验设计

实验共比较六个模型： Decision Tree、AdaBoost + Decision Tree，以及四种核函数下的 SVM，分别为 Linear、Polynomial、RBF 和 Sigmoid。本文保留 Sigmoid 核作为对照项，以观察“非线性核”并不必然带来性能提升这一现象。

所有模型均通过 5 折交叉验证选择超参数。Decision Tree 搜索最大深度、叶节点最小样本数和划分准则；AdaBoost 搜索基学习器深度、弱分类器数量和学习率；SVM 则分别搜索各核函数对应的 C、γ、多项式阶数与 coef0。评价指标采用

Accuracy、Precision、Recall 和 F1，同时保留训练集准确率与混淆矩阵，用于判断欠拟合、过拟合及误分类分布。

一方面，交叉验证可降低单次调参带来的偶然性；另一方面，训练准确率、测试准确率和混淆矩阵的联合分析，能够为后续讨论边界表达能力与泛化差异提供更直接的依据。

五． 主要实验结果

表 1 给出了固定随机种子下的主要结果。总体来看，多项式核 SVM、RBF 核 SVM 与 AdaBoost 构成第一梯队，Decision Tree 次之，线性核与 Sigmoid 核明显落后。

模型	验证准确率	训练准确率	测试准确率	Precision	Recall	F1	训练-测试差
SVM (Polynomial)	0.984	0.987	0.978	0.9799	0.9760	0.9780	0.009
AdaBoost + Decision Tree	0.980	1.000	0.972	0.9797	0.9640	0.9718	0.028
SVM (RBF)	0.987	0.987	0.972	0.9797	0.9640	0.9718	0.015
Decision Tree	0.947	1.000	0.934	0.9222	0.9480	0.9349	0.066
SVM (Sigmoid)	0.825	0.837	0.836	0.8360	0.8360	0.8360	0.001
SVM (Linear)	0.672	0.673	0.672	0.6792	0.6520	0.6653	0.001

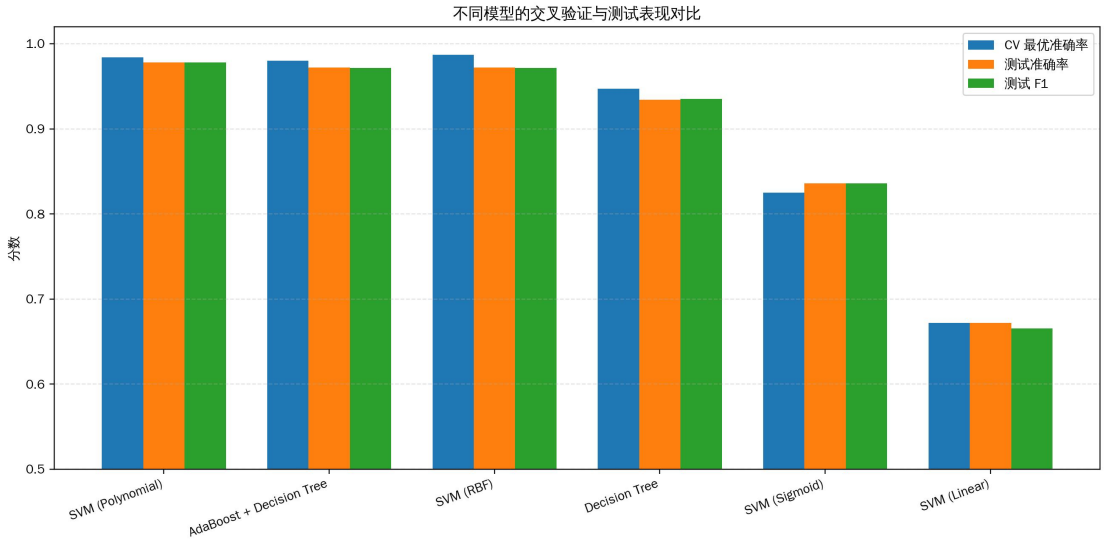

图 2 不同模型的交叉验证与测试表现对比。

多项式核 SVM 的测试准确率达到 97.8%，训练集与测试集差距仅为 0.9 个百分点，在边界表达能力和泛化性能之间取得了较好平衡。与类似任务中常见的经验相比，这一结果略偏向多项式核而非 RBF 核；结合参数搜索结果看，三次多项式核已足以刻画该数据的主要弯曲结构，而较小的 C 值又抑制了对局部噪声的过度贴合。

RBF 核 SVM 与 AdaBoost 的测试准确率同为 97.2%，但二者的拟合特征并不相同。RBF 核的训练准确率为 98.7%，整体处于适度拟合状态；AdaBoost 的训练准确率达到 100%，表明其对训练样本的贴合更强，不过集成方式改善了边界表示，因此测试性能仍保持在较高水平。

Decision Tree 的主要问题在于泛化不足。该模型在训练集上达到 100% 准确率，但测试准确率仅为 93.4%，训练与测试之间相差 6.6 个百分点，是高性能模型中差距最大的一个。这表明单棵树虽然能够通过持续切分贴合训练样本，但面对连续弯曲的真实边界时，轴对齐分割容易形成块状、锯齿状区域，从而削弱泛化能力。

线性核与 Sigmoid 核则表现出明显欠拟合。线性核在训练集和测试集上的准确率均约为 67.2%，说明单一超平面无法处理该数据的非线性结构；Sigmoid 核虽优于线性核，但准确率仍只有 83.6%，未能形成足够有效的几何映射。

为了进一步观察误分类分布，图 3 给出了测试集上的混淆矩阵。

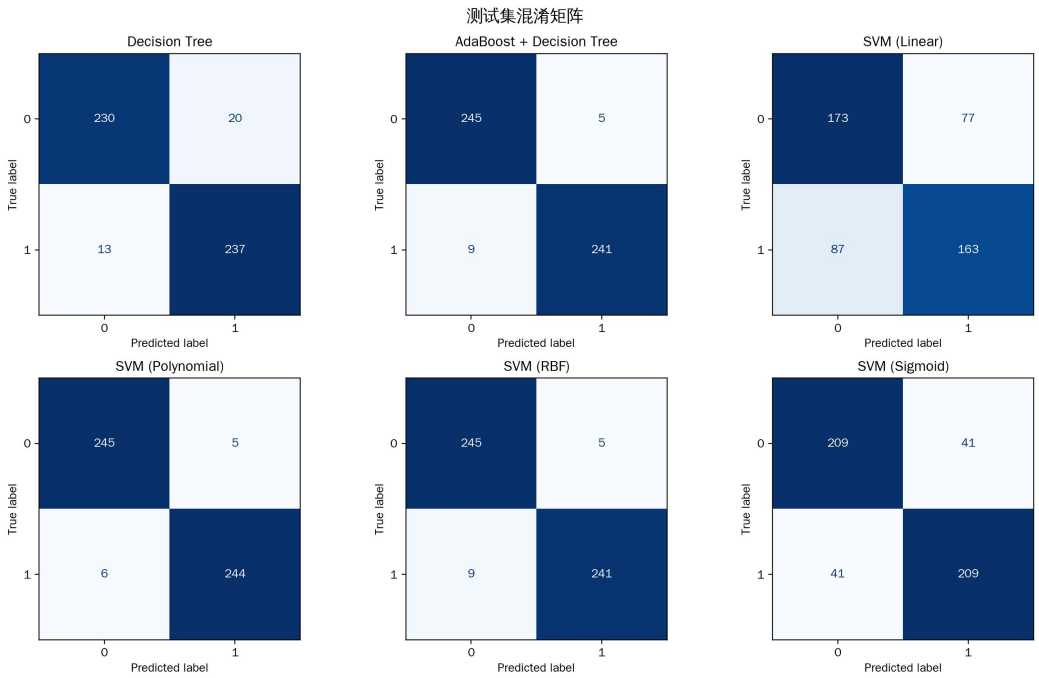

图 3 各模型在测试集上的混淆矩阵

混淆矩阵反映，多项式核 SVM 仅错分 11 个样本，RBF 核与 AdaBoost 各错分 14 个样本，Decision Tree 错分 33 个样本。线性核的错误在两类样本之间分布较为均匀，反映出其整体边界能力不足，而非对某一类别存在明显偏置。

六. 深入分析

1. 决策边界为什么会拉开差距

固定 $z = 0$ 进行切片后，不同模型的边界差异更容易观察。

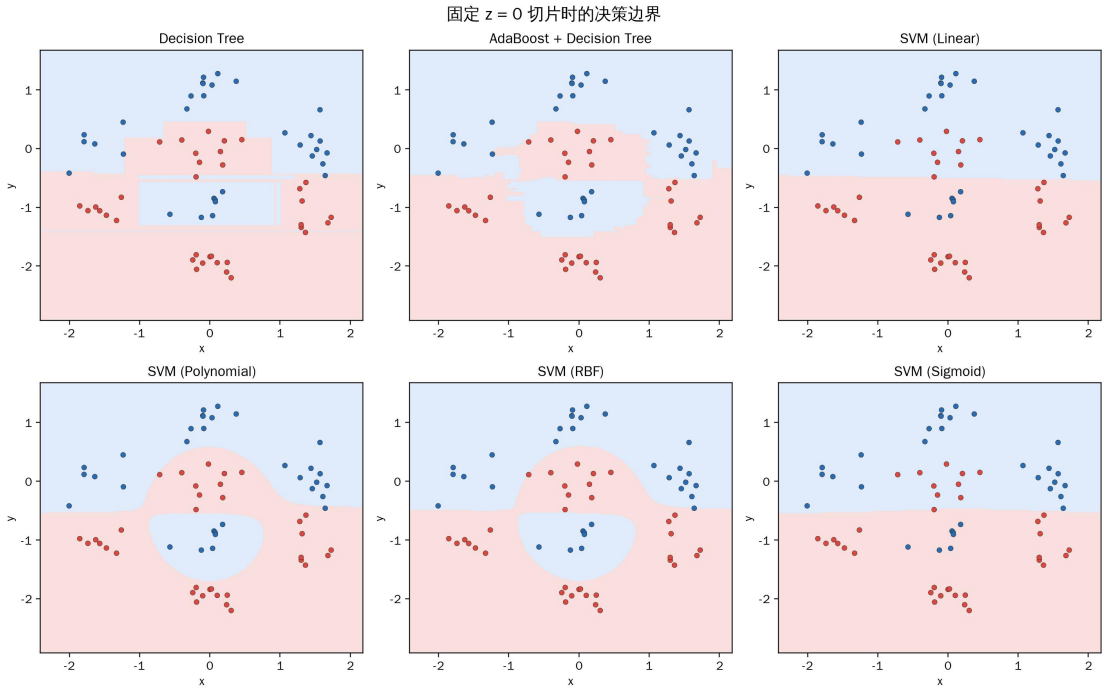

图 4 固定 z = 0 时，各模型的二维切片决策边界

从图 4 可见，Decision Tree 的边界呈明显块状，局部存在突起和凹陷，这是轴对齐切分的直接结果。AdaBoost 叠加多棵浅层树后，边界较单棵树平滑，但局部仍保留碎片化纹理。线性核 SVM 基本对应一条近似直线，难以贴合数据结构；Sigmoid 核虽具备一定弯曲能力，但整体边界仍显僵硬。

相比之下，多项式核与 RBF 核形成了更平滑的封闭区域，能够较好包裹中心附近的样本，同时避免在外部区域产生过多无意义的弯折。两者之所以明显优于其余模型，关键不在于模型“更复杂”，而在于边界形状与数据几何结构更为匹配。

2. RBF 核的参数敏感性

RBF 核通常被视为处理非线性问题的稳健选择，但其效果仍然依赖参数设定。图 5 展示了不同 C 和 γ 组合下的 5 折交叉验证准确率。

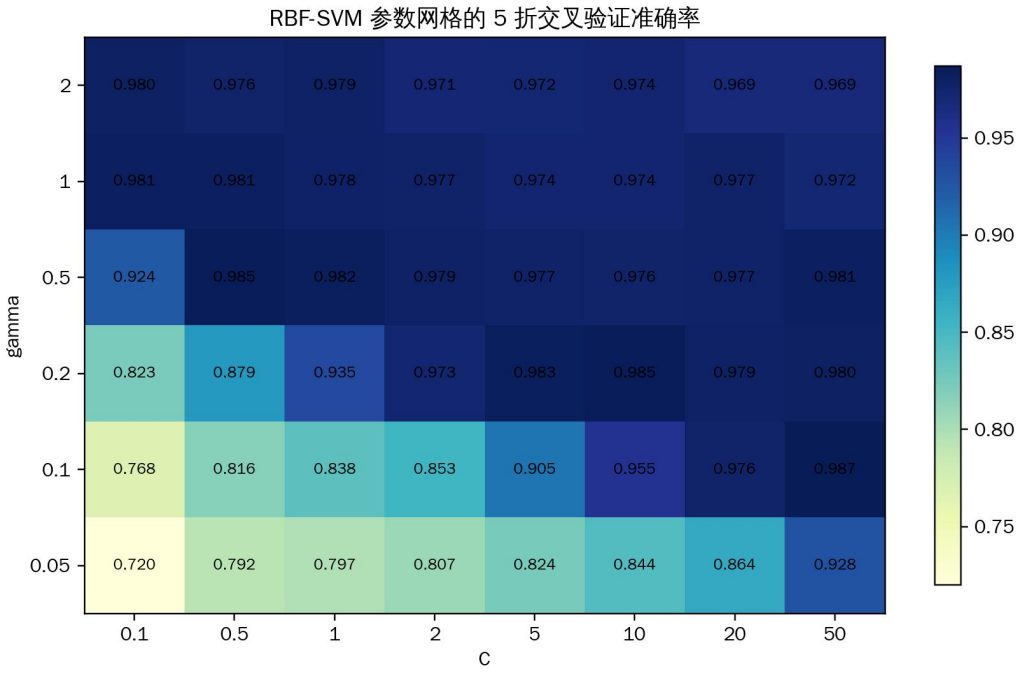

图 5 RBF-SVM 参数网格的 5 折交叉验证准确率

当 γ 较小时，模型边界明显偏平滑。例如在 $\gamma = 0.05$ 时，即使将 C 提高到 50，最佳交叉验证准确率也仅为 0.928。这表明单个样本的影响范围过大时，模型难以跟随数据边界的弯曲变化。

当 γ 进入 0.1 到 0.5 的区间后，结果明显改善。例如 $\gamma = 0.1,\ C = 50$ 时交叉验证准确率达到 0.987；$\gamma = 0.2,\ C = 10$ 和 $\gamma = 0.5,\ C = 0.5$ 时也都接近 0.985。对于当前数据而言，适中的局部性既能提供足够的边界弯曲能力，又不会被噪声过度牵引。

继续增大 γ 至 1 或 2 后，准确率并未进一步显著提升，说明模型已开始偏向局部拟合，复杂度增加所带来的收益有限。由此可见，RBF 核的优势并非来自单纯提高灵活度，而是来自对边界平滑性与局部性的恰当平衡。

3. 稳健性分析

为检验结论是否依赖单次随机采样，本文在固定各模型最优超参数后，重新生成 10 组训练集与测试集，并统计测试准确率分布。

模型	10 组随机数据平均测试准确率	标准差
SVM (Polynomial)	0.9804	0.0070
SVM (RBF)	0.9794	0.0082
AdaBoost + Decision Tree	0.9736	0.0068
Decision Tree	0.9458	0.0094
SVM (Sigmoid)	0.8298	0.0082
SVM (Linear)	0.6708	0.0100

由表可得，多项式核与 RBF 核仍位于最前列，平均准确率分别为 98.04% 和 97.94%，波动均控制在 1 个百分点以内。AdaBoost 的均值略低于两种核方法，但标准差仅为 0.0068，稳定性同样较好。Decision Tree 的均值明显落后，且波动相对更大，这与其更易过拟合的特征一致。

4. 从支持向量数量看模型复杂度

除准确率外，支持向量数量也能反映核方法是否找到了合适的分离方式。本文最优模型中，线性核需要 612 个支持向量，Sigmoid 核需要 469 个，多项式核仅需 165 个，RBF 核为 194 个。

这一现象表明，当核函数与数据几何结构匹配时，模型可以依赖较少的关键样本构造有效边界；当核函数不匹配时，则往往需要更多样本维持分隔面，但性能仍难以同步提升。多项式核与 RBF 核的优势不仅体现在准确率上，也体现在其决策边界组织方式更符合数据本身的形态。

七. 结论

本实验表明，3D Make-Moons 数据的核心特征并非单纯的“非线性”，而是连续、平滑的弯曲边界。能够构造平滑决策曲面的模型在该任务上更具优势，其中多项式核 SVM 与 RBF 核 SVM 的整体表现最为稳定。

AdaBoost 明显优于单棵 Decision Tree，说明树模型经过集成后仍可取得较强性能；但从训练集与测试集差距、边界形态以及稳健性结果来看，其泛化方式与核方法仍存在差异。单棵 Decision Tree 更容易形成离散、块状边界，因此在该数据上表现出更明显的过拟合风险。

SVM 的效果高度依赖核函数选择。线性核与 Sigmoid 核未能有效刻画数据结构，而多项式核与 RBF 核能够较好匹配数据几何形态。由此可见，模型优劣并非由复杂度单独决定，关键在于边界形式是否与任务本身相适配。

八. 附录：最优参数设置

模型	最优参数
Decision Tree	criterion=entropy, max_depth=None, min_samples_leaf=1
AdaBoost + Decision Tree	base_depth=4, n_estimators=300, learning_rate=0.5
SVM (Linear)	C=2
SVM (Polynomial)	C=0.1, degree=3, gamma=1.0, coef0=1.0
SVM (RBF)	C=50, gamma=0.1
SVM (Sigmoid)	C=10, gamma=0.1, coef0=-1.0