基于多变量 LSTM 的 PM2.5 小时级预测实验报告

摘要

本实验以空气质量逐小时数据为对象，研究利用历史污染浓度和气象变量预测下一小时 PM2.5 浓度的方法。数据包含 PM2.5、露点、温度、气压、风向、累计风速、累计降雪和累计降雨等变量。实验将原始时间序列转换为滑动窗口监督学习样本，分别构建不同历史窗口长度下的 Residual-LSTM 模型，并设置 Persistence、Ridge 和 HistGradientBoosting 作为对照模型。

实验结果显示，在本次设置下，Residual-LSTM 使用 12 小时窗口时取得较低误差，测试集 MAE 为 14.04，RMSE 为 26.40，R^2 为 0.9286。模型对比中，HistGradientBoosting 的 RMSE 为 24.78，略低于 Residual-LSTM，说明在该测试集上，基于树的非线性回归模型也具有较强竞争力。特征消融结果表明，历史 PM2.5 是短期预测中最主要的信息来源，仅使用气象变量时误差明显增大。进一步的残差分析和空气质量等级混淆矩阵显示，模型能够较好跟随整体变化趋势，但在高浓度区间误差有所增大。

关键词：PM2.5 预测；多变量时间序列；LSTM；滑动窗口；特征消融；残差分析

1 引言

PM2.5 浓度受污染物累积、气象扩散条件和区域输送等因素共同影响，具有明显的时间相关性和非线性波动特征。对于小时级预测任务，当前时刻附近的污染水平通常会对下一小时浓度产生直接影响；同时，温度、湿度、风向和风速等气象条件也会改变污染物扩散和滞留状态。因此，本实验将 PM2.5 预测建模为多变量时间序列回归问题。

传统回归模型可以处理静态特征关系，但难以直接保留变量在连续时间窗口中的顺序信息。LSTM 通过门控结构对序列中的历史信息进行选择性保留，适合用于处理具有时间依赖关系的数据。本实验在普通 LSTM 思路上采用残差形式：以最近一小时 PM2.5 作为基准，LSTM 学习预测值相对于该基准的修正量。这样做并不是改变预测任务，而是利用短期 PM2.5 的强自相关性，使模型训练更加稳定。

实验重点不只放在单个模型结果上。报告同时比较了不同时间窗口、不同模型和不同特征组合的预测效果，并通过残差分布、污染等级误差和置换重要性分析模型表现。这样的设计可以更清楚地说明模型在哪些情况下有效，在哪些情况下仍存在局限。

2 数据集与预测任务

2.1 数据说明

实验使用的训练数据共有 43800 条逐小时记录，时间范围为 2010-01-02 00:00:00 至 2014-12-31 23:00:00。测试数据共有 346 条记录，约对应连续 14 天的逐小时观测。测试文件中没有日期列，为了构造 hour 和 month 周期特征，实验按训练集结束时间之后的连续小时补齐测试集时间，即测试时间被推定为 2015-01-01 00:00:00 至 2015-01-15 09:00:00。

数据字段包括 pollution、dew、temp、press、wnd_dir、wnd_spd、snow、rain。其中 pollution 表示 PM2.5 浓度，是本实验的预测目标；其他变量作为气象和环境输入特征。训练集中 PM2.5 最小值为 0，最大值为 994。测试集包含真实 pollution 值，因此可以直接用于误差评估。

表 1 给出实验中使用的数据基本信息。

表 1 数据集基本信息

数据集	样本数	时间说明	主要字段
训练集	43800	2010-01-02 至 2014-12-31，逐小时	pollution, dew, temp, press, wnd_dir, wnd_spd, snow, rain
测试集	346	推定为 2015-01-01 至 2015-01-15，逐小时	pollution, dew, temp, press, wnd_dir, wnd_spd, snow, rain

图 1 展示了训练集中 PM2.5 随时间的变化情况。从图中可以看到，PM2.5 浓度具有明显波动，并存在若干高污染峰值。这说明预测任务不能只关注平均趋势，也需要观察模型在高浓度区间的误差。

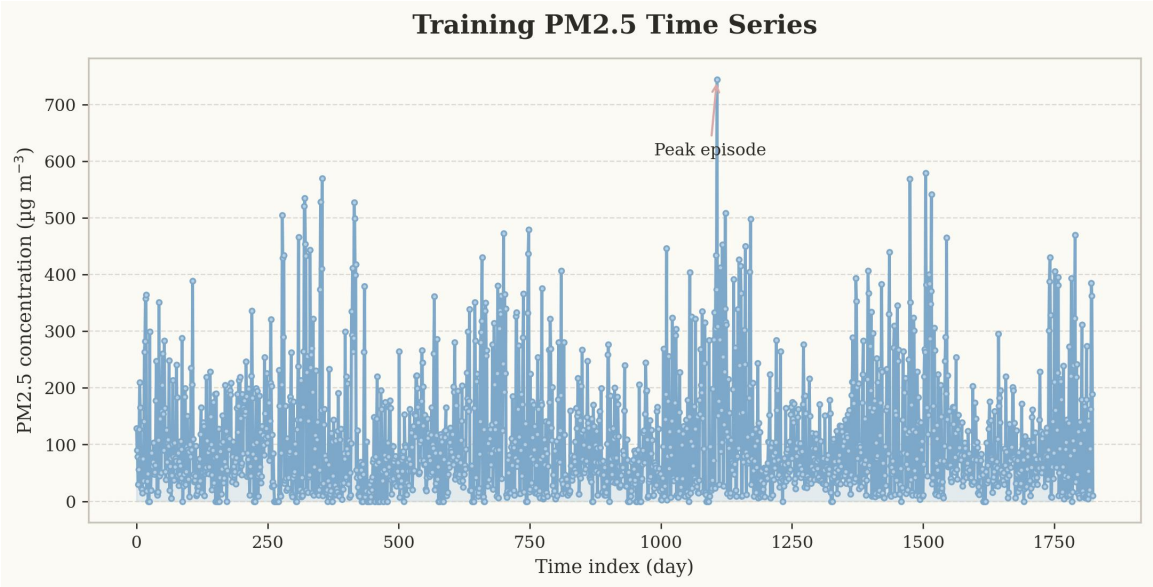

图 1 训练集 PM2.5 时间序列

图 2 给出了训练集中 PM2.5 的分布。样本主要集中在较低浓度区间，高浓度样本数量相对较少，整体呈右偏分布。这种分布会影响模型训练，因为常规浓度区间在损失函数中占据更多样本比例，极端污染点的拟合难度相对更高。

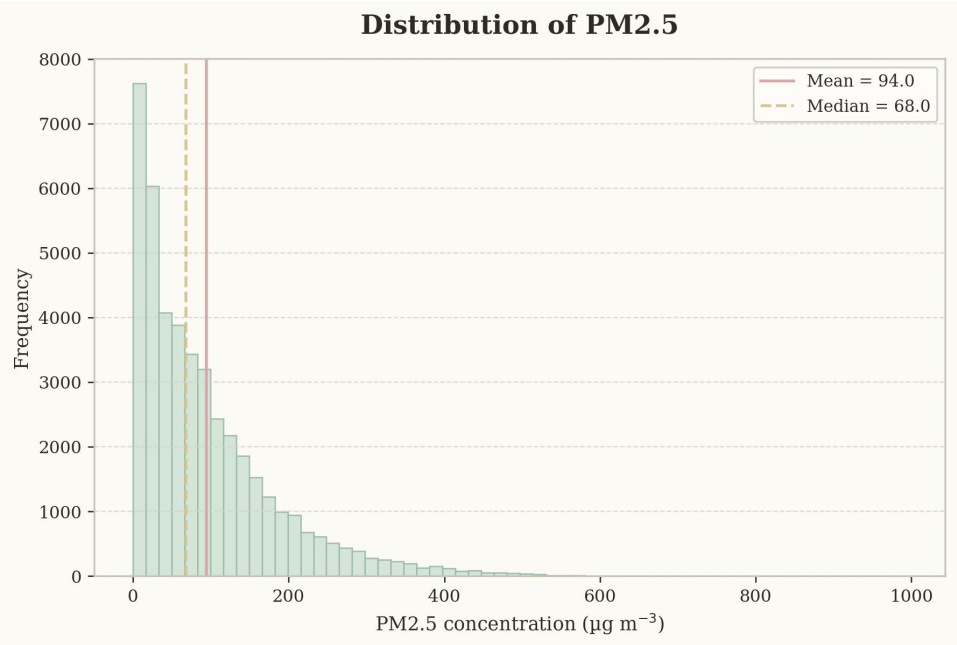

图 2 PM2.5 浓度分布

图 3 是按月份统计的平均 PM2.5。该图反映了数据中的季节性差异，说明在建模中加入月份周期特征是有必要的。由于月份是循环变量，实验没有直接使用整数月份，而是使用 sin/cos 形式表达周期关系。

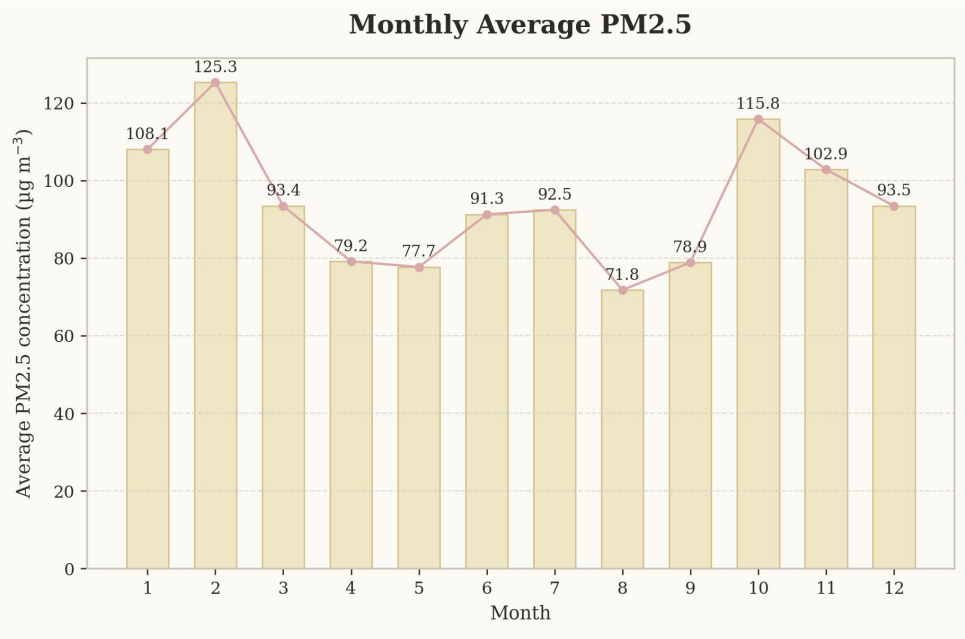

图 3 各月份平均 PM2.5

2.2 预测任务定义

本实验采用单步预测策略。给定过去 L 小时的多变量观测序列，预测下一小时 PM2.5 浓度。设第 t 时刻输入特征为 X_t，目标值为 y_t，窗口长度为 L，模型学习的映射关系可表示为：

$$\hat{y}_{t+1} = f_\theta(X_{t-L+1}, X_{t-L+2}, \ldots, X_t)$$

其中 X_t 包含 PM2.5 历史值和气象变量。窗口长度 L 在实验中取 1、6、12、18、24、48 小时，用于观察历史信息长度对预测效果的影响。

3 数据预处理与特征工程

3.1 缺失值处理

污染和气象变量均按时间顺序排列。对于数值特征，实验采用线性插值处理缺失值，并对首尾仍无法插值的位置使用前向填充和后向填充。风向变量为类别特征，使用前向填充和后向填充补齐。这样的处理方式保留了时间序列的连续性，避免直接删除记录导致时间窗口断裂。

3.2 类别特征编码

风向变量 wnd_dir 是类别型变量，不能直接作为数值输入。实验对训练集中出现的风向类别进行 One-hot 编码，得到 wnd_dir_NE、wnd_dir_NW、wnd_dir_SE、wnd_dir_cv 四个二值特征。测试集使用与训练集相同的风向列集合，保证输入维度一致。

3.3 周期特征构造

小时和月份具有循环特征。若直接使用整数编码，23 点和 0 点会被认为距离较远，12 月和 1 月也会出现类似问题。实验使用 sin/cos 编码构造周期特征：

$$hour_sin = \sin\left(\frac{2\pi\, hour}{24}\right), \quad hour_cos = \cos\left(\frac{2\pi\, hour}{24}\right)$$

$$month_sin = \sin\left(\frac{2\pi\, month}{12}\right), \quad month_cos = \cos\left(\frac{2\pi\, month}{12}\right)$$

这样可以保留时间变量的循环关系，使模型更容易利用日周期和季节周期信息。

3.4 数值归一化

实验对 pollution、dew、temp、press、wnd_spd、snow、rain 进行 Min-Max 归一化。归一化参数只在训练集上计算，测试集使用训练集的最小值和最大值进行变换，避免测试集信息泄露到训练过程。模型输出在评估时反归一化回原始 PM2.5 尺度，因此报告中的 MAE 和 RMSE 主要使用原始尺度，便于理解误差大小。

归一化公式为：

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$

反归一化公式为：

$$\hat{y} = \hat{y}'(y_{max} - y_{min}) + y_{min}$$

3.5 输入特征

完整模型使用 17 个输入特征，具体为：

表 2 输入特征组成

类型	特征
污染历史特征	pollution
气象连续特征	dew, temp, press, wnd_spd, snow, rain
雨雪事件特征	is_snow, is_rain
风向特征	wnd_dir_NE, wnd_dir_NW, wnd_dir_SE, wnd_dir_cv
时间周期特征	hour_sin, hour_cos, month_sin, month_cos

图 4 展示了部分连续变量之间的相关性。相关性热力图用于观察线性关系，但不能完全代表 LSTM 的非线性建模过程。图中 pollution 与部分气象变量存在相关关系，说明气象因素可能为预测提供辅助信息；同时，相关性并不等于因果关系，因此后续还需要结合模型实验和置换重要性进行判断。

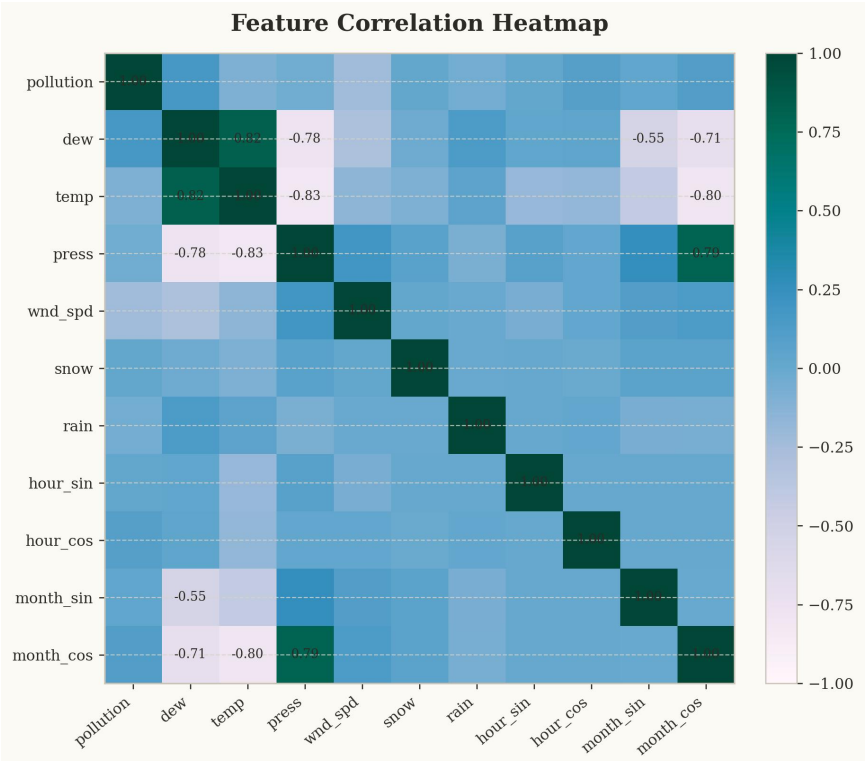

图 4 特征相关性热力图

4 模型与评价指标

4.1 Residual-LSTM 模型

本实验的主模型为 Residual-LSTM。普通 LSTM 直接输出下一小时 PM2.5，而 Residual-LSTM 将最近一小时 PM2.5 作为基准，让网络学习一个修正量：

$$\hat{y}_{t+1} = y_t + g_\theta(X_{t-L+1}, \ldots, X_t)$$

其中 y_t 为窗口中最后一个时间步的 PM2.5，g_θ 为 LSTM 网络输出的残差修正。该设计适合短期预测任务，因为 PM2.5 在相邻小时之间通常具有较强连续性。模型结构包括一层 LSTM、一个小型全连接层和输出层。训练时使用 Adam 优化器，损失函数为 MSE。

实验中 Residual-LSTM 的主要设置如下：

表 3 Residual-LSTM 主要参数

参数	设置
LSTM 隐藏单元数	32
Batch size	2048
学习率	0.001
损失函数	MSE
优化器	Adam
梯度裁剪	1.0
窗口实验训练轮数	4
随机种子	42

窗口实验和消融实验均使用相同训练轮数，主要是为了保证不同实验之间比较条件一致。由于训练轮数较少，结果更适合用于课程实验中的方法比较，不宜解释为充分调参后的极限性能。

图 5 给出了实验总体流程。该图从原始数据、预处理、特征构造、模型实验到结果分析依次展开，有助于说明整套实验的组织方式。

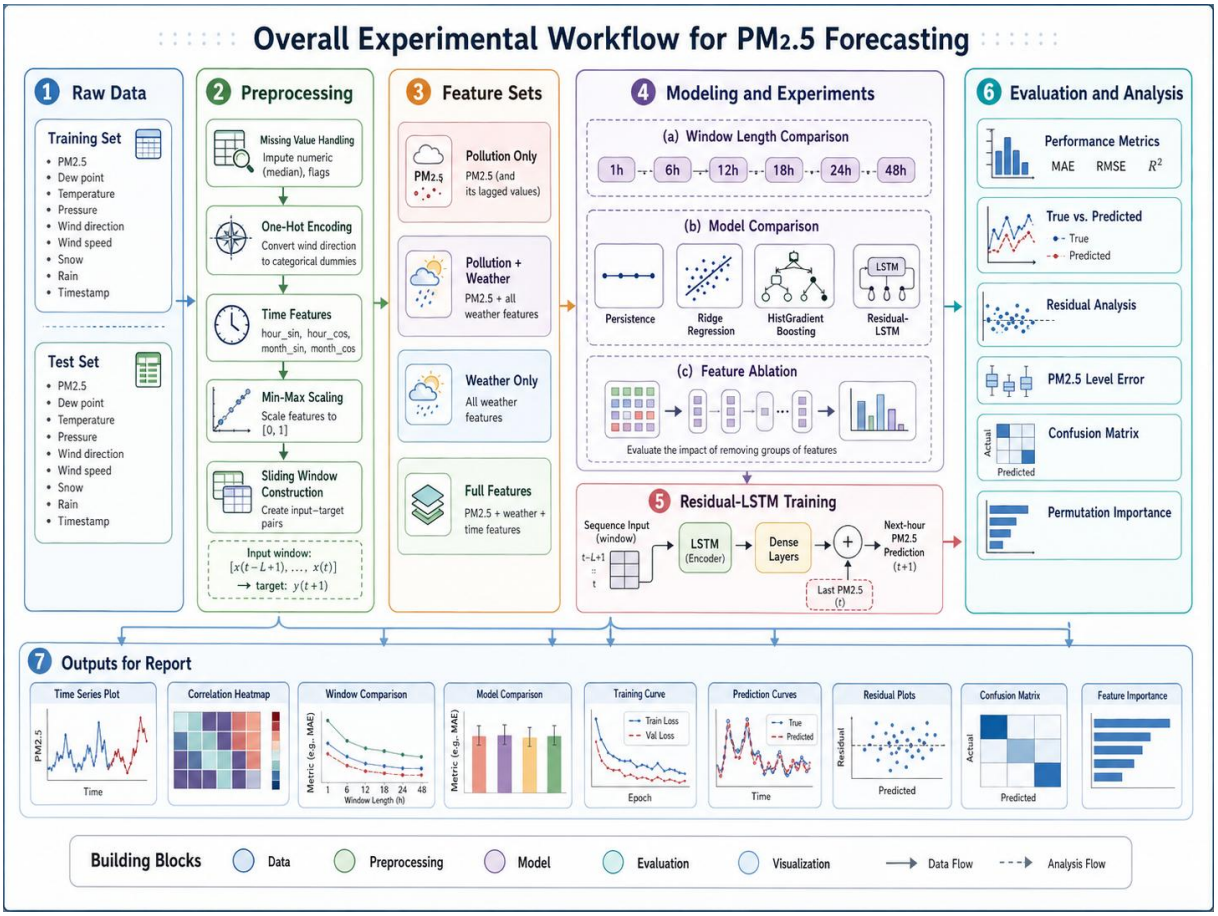

图 5 实验总体流程图

图 6 展示了 Residual-LSTM 的模型结构。图中保留了输入序列、LSTM 层、全连接头和残差加和的完整路径，可以直观说明模型为什么被称为 Residual-LSTM。

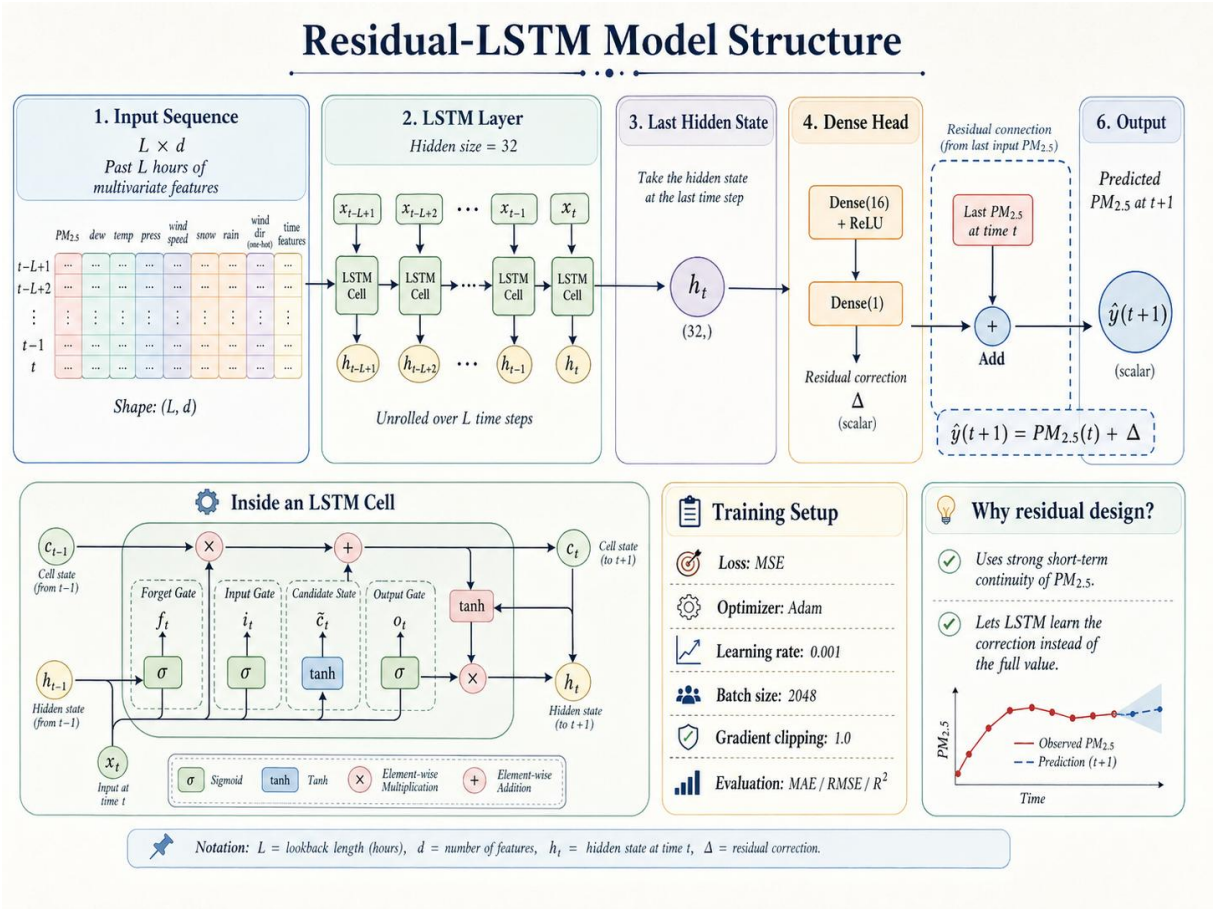

图 6 Residual-LSTM 模型结构图

4.2 对照模型

为避免只观察单个 LSTM 模型，本实验设置了三个对照模型。Persistence 使用窗口最后一小时 PM2.5 直接作为下一小时预测值，是最简单的时间序列基线。如果复杂模型不能超过该基线，说明模型没有充分利用额外信息。Ridge 将滑动窗口展平成二维特征后进行线性回归，用于观察线性模型在该任务上的表现。HistGradientBoosting 同样使用展平窗口特征，但可以拟合非线性关系。它不显式建模序列结构，但对表格型特征具有较强表达能力，因此可以作为较有竞争力的传统机器学习对照。

4.3 评价指标

实验采用 MAE、RMSE 和 R^2 评估模型。MAE 反映平均绝对误差，RMSE 对较大误差更敏感，R^2 表示模型相对于均值预测的解释能力。

$$MAE = \frac{1}{N}\sum_{i=1}^{N}|y_i - \hat{y}_i|$$

$$RMSE = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2}$$

$$R^2 = 1 - \frac{\sum_{i=1}^{N}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{N}(y_i - \bar{y})^2}$$

除特别说明外，本文表格中的 MAE 和 RMSE 均为反归一化后的 PM2.5 原始尺度误差。

5 实验设计

实验分为五部分。

时间窗口实验比较 L=1、6、12、18、24、48 小时时 Residual-LSTM 的预测效果，用于分析历史信息长度对模型的影响。

模型对比实验在窗口实验得到的较优窗口下比较 Persistence、Ridge、HistGradientBoosting 和 Residual-LSTM，观察 LSTM 相对于简单基线和传统机器学习模型的表现。

特征消融实验比较不同输入特征组合，包括仅使用历史 PM2.5、仅使用气象变量、PM2.5 加气象变量、完整特征。该实验用于判断多变量信息是否确实带来收益。

误差分析实验绘制真实值与预测值曲线、散点图、残差分布和残差随真实 PM2.5 的变化关系，用于观察模型在哪些区间误差较大。

应用分析将 PM2.5 按 0–35、35–75、75–115、115–150、>150 分段，统计不同污染等级下的误差，并绘制等级混淆矩阵。这部分不是把回归任务改成分类任务，而是从空气质量等级角度观察预测结果是否具有实际解释性。

6 实验结果与分析

6.1 时间窗口长度对预测效果的影响

表 4 给出不同历史窗口长度下 Residual-LSTM 的测试结果。

表 4 不同窗口长度下的测试结果

窗口长度	MAE	RMSE	R^2
1h	15.93	28.36	0.9168
6h	19.67	30.96	0.9022
12h	14.04	26.40	0.9286
18h	14.38	26.60	0.9285
24h	17.47	28.99	0.9164
48h	15.75	27.79	0.9211

从表中可以看出，12 小时窗口在本次实验设置下取得较低 RMSE，18 小时窗口与其接近。1 小时窗口虽然利用的信息较少，但由于 PM2.5 短期自相关较强，误差并不高。6 小时和 24 小时窗口在本次训练中表现相对较差，说明窗口长度并不是越长越好。过长窗口会引入更多历史信息，但这些信息未必都对下一小时预测有用，也会增加模型学习难度。

图 7 将各窗口的 MAE 和 RMSE 放在一起比较。图中可以看到，12 小时和 18 小时窗口的误差较低，二者差异很小，因此不宜简单认为某个窗口具有绝对优势。考虑本实验采用固定训练轮数，窗口结果可以说明半日尺度历史信息较适合该测试集，但仍需要更多训练和交叉时间段验证才能得出更稳健结论。

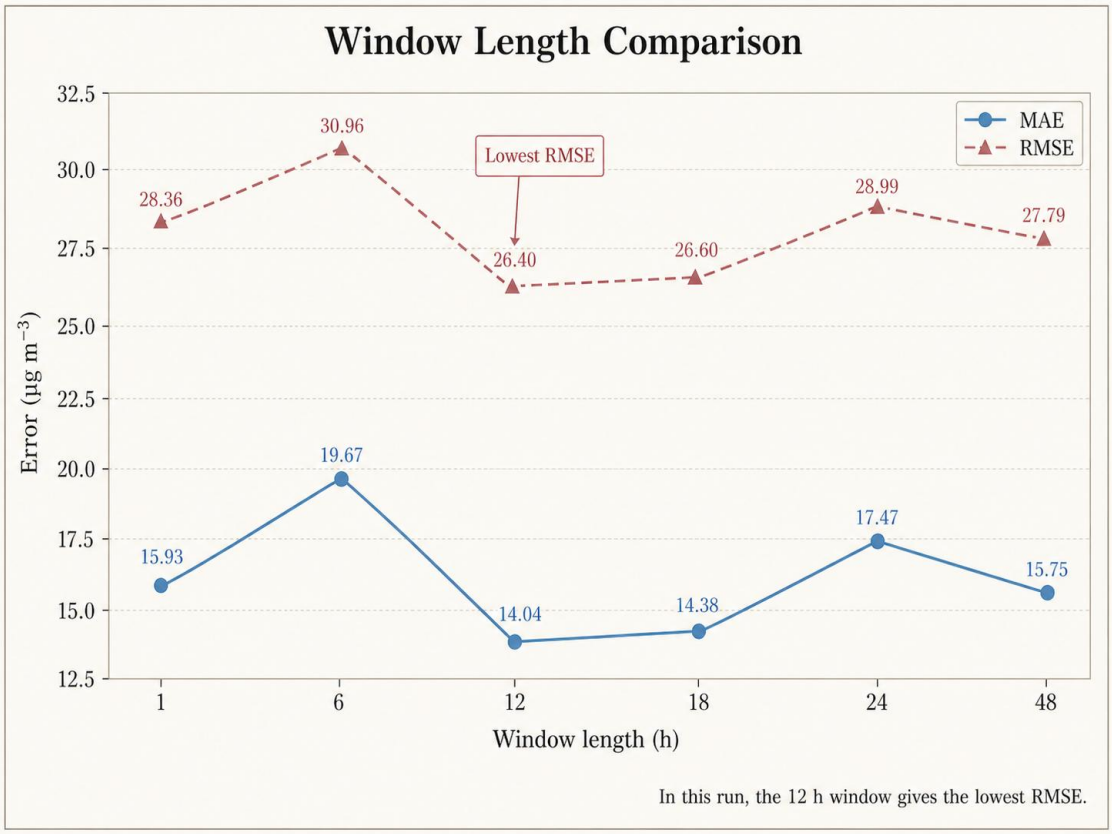

图 7 时间窗口长度对误差的影响

6.2 不同模型的预测结果

基于窗口实验结果，模型对比采用 12 小时窗口。表 5 给出四种模型的测试结果。

表 5 不同模型测试结果

模型	MAE	RMSE	R^2
HistGradientBoosting	13.71	24.78	0.9371
Ridge	14.88	26.21	0.9296
Residual-LSTM	14.04	26.40	0.9286
Persistence	14.51	26.88	0.9260

HistGradientBoosting 在该测试集上取得最低 RMSE。Residual-LSTM 的 MAE 低于 Persistence，但 RMSE 与 Ridge 接近，略高于 Ridge。这说明 LSTM 在本次实验中能够利用历史序列进行预测，但相较简单基线的改进幅度并不大。短期 PM2.5 本身具有较强连续性，使 Persistence 已经是一个不弱的基线。

图 8 展示了模型对比结果。图中说明，复杂模型之间的误差差距并不悬殊，而 HistGradientBoosting 略占优势。这一结果提示，在样本规模有限、预测步长较短的任务中，传统非线性模型仍然值得作为对照，而不能默认深度时序模型一定表现更好。

图 8 不同模型预测误差对比

6.3 特征消融实验

表 6 给出不同特征组合下 Residual-LSTM 的结果。

表 6 特征消融实验结果

特征组合	特征数	MAE	RMSE	R^2
仅 pollution	1	14.60	26.60	0.9275
pollution + weather	9	14.73	26.71	0.9269
完整特征	17	14.79	26.82	0.9263
仅 weather	16	71.40	86.21	0.2387

该实验结果比较直接。仅使用气象变量时误差明显增大，说明缺少历史 PM2.5 后，模型难以完成下一小时浓度预测。仅使用 pollution 已经可以取得接近完整特征的结果，说明短期预测中 PM2.5 自身历史信息占主要作用。

完整特征并没有在本次消融实验中降低误差。这个结果不能解释为气象变量没有意义，更合理的理解是：在下一小时预测中，历史 PM2.5 已经包含了大量近时信息，测试集长度也较短，气象变量带来的增益没有稳定体现出来。若预测步长扩展到未来 6 小时或 24 小时，气象变量可能会更重要。

图 9 展示了各特征组合的误差。图中最明显的是 weather only 的误差明显高于其他组合，说明历史污染浓度是该任务的核心输入。

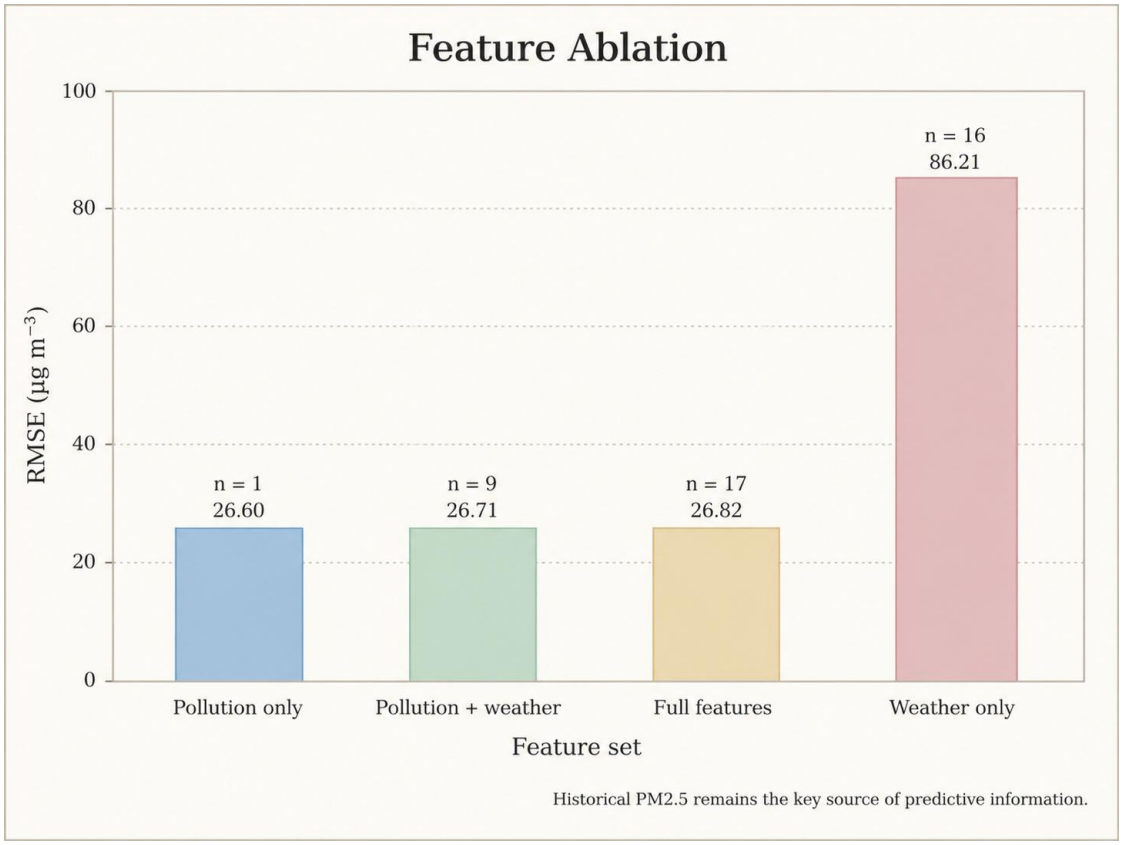

图 9 特征消融实验结果

6.4 训练过程与预测曲线

图 10 是 12 小时窗口 Residual-LSTM 的训练曲线。训练集和验证集 RMSE 在训练过程中下降，未出现明显分离。由于训练轮数较少，曲线主要用于观察模型是否可以正常收敛，而不适合用于判断已经达到充分训练状态。

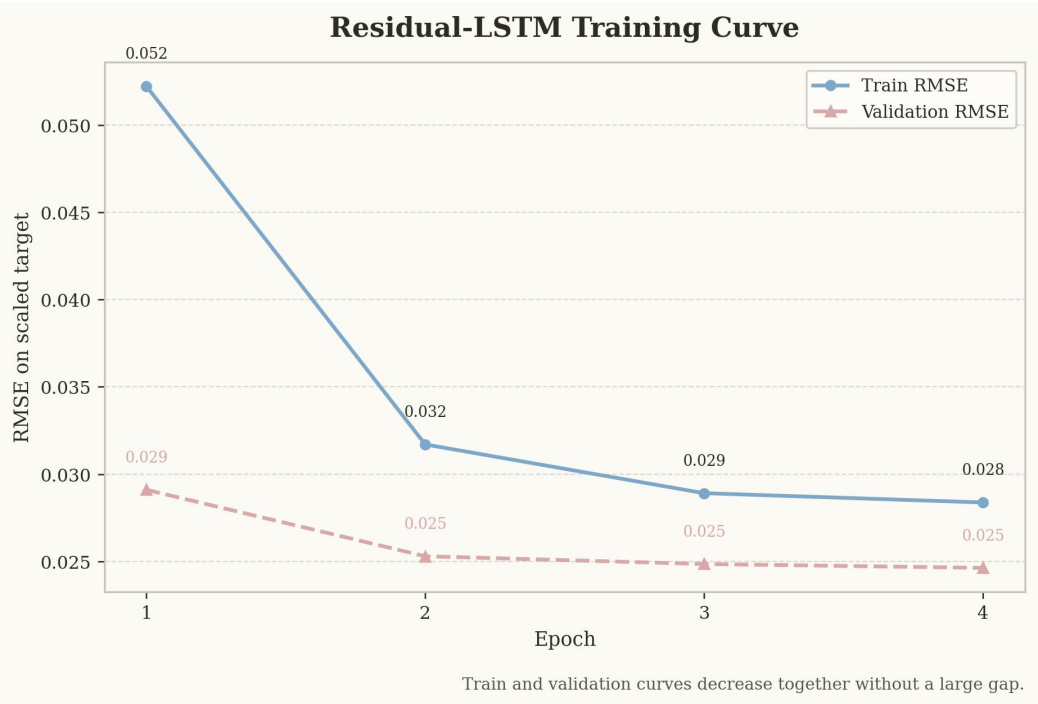

图 10 Residual-LSTM 训练曲线

图 11 给出了测试集上真实 PM2.5 与 Residual-LSTM 预测值的整体对比。预测曲线大体跟随真实曲线的上升和下降，在多数低浓度和中等浓度区间能够保持接近。高峰附近仍存在低估或滞后现象，这与短期突发污染事件较难预测有关。

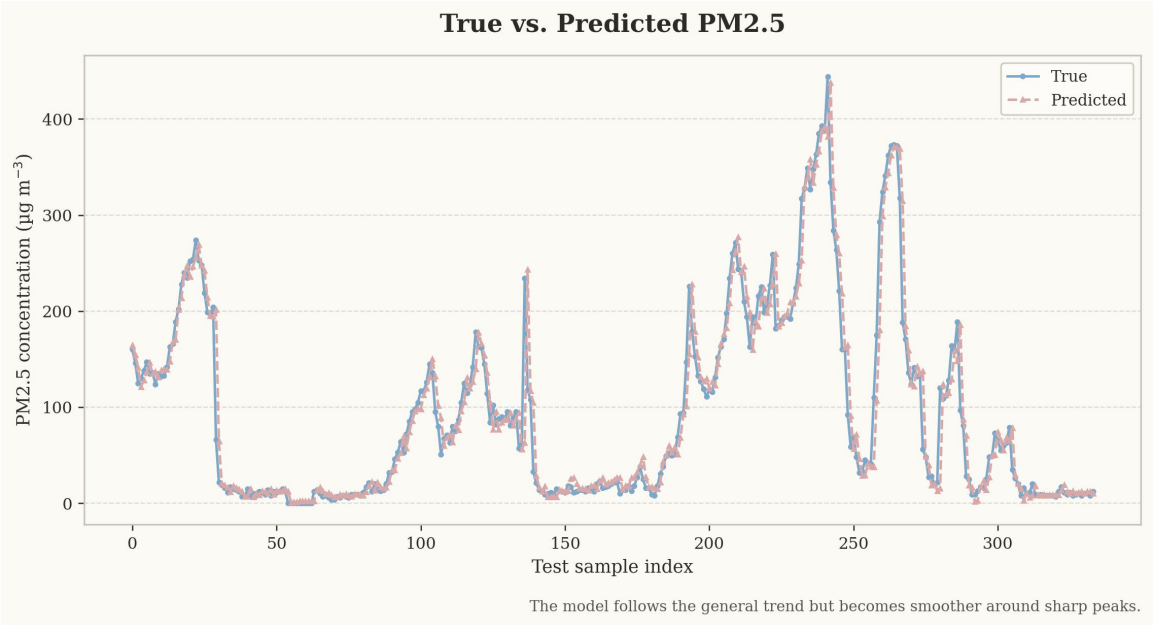

图 11 测试集真实值与预测值对比

图 12 放大了测试集前 160 个样本。局部图可以更清楚地看到，在变化较平缓的区间，预测值与真实值较接近；当 PM2.5 出现快速上升或下降时，预测曲线会变得更平滑，说明模型倾向于拟合常规变化，而对突发波动的响应不足。

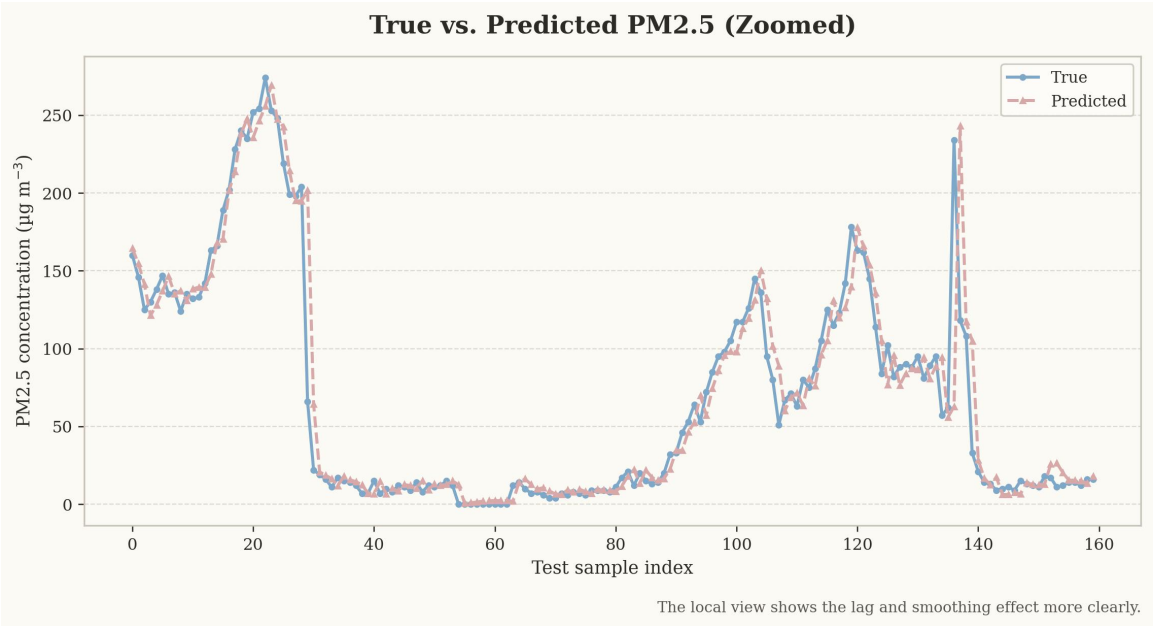

图 12 测试集局部预测效果

图 13 是预测值与真实值的散点图。散点整体分布在对角线附近，说明模型具有较好的整体拟合能力。高浓度区域的散点离散程度更大，说明污染峰值附近误差更不稳定。

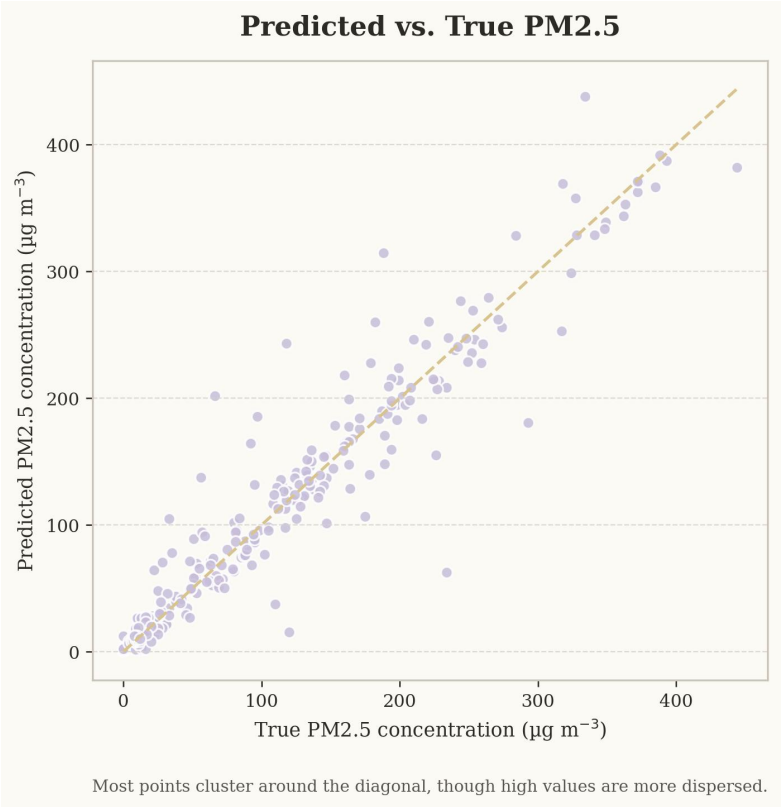

图 13 预测值与真实值散点图

6.5 残差分析

图 14 展示了 Residual-LSTM 的残差分布。残差大多集中在零附近，说明模型整体偏差不大。但分布仍有一定长尾，表示少数样本存在较大预测误差。

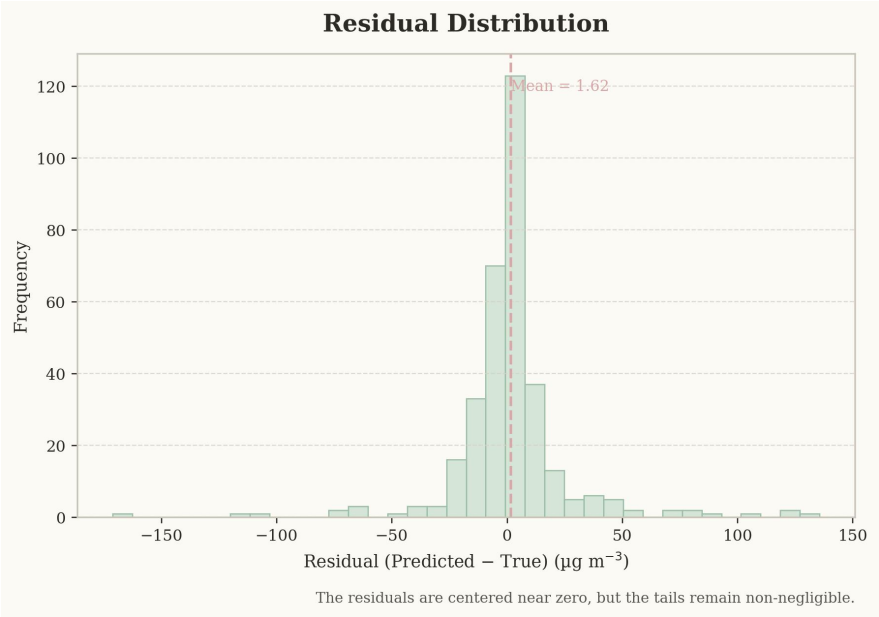

图 14 残差分布

图 15 将残差与真实 PM2.5 浓度对应起来。可以看到，真实浓度较高时残差波动范围更大。这与图 13 的观察一致：模型在常规浓度区间较稳定，在高污染峰值附近误差更大。该现象与训练数据分布有关，高浓度样本相对较少，模型更容易学习到常规区间的变化模式。

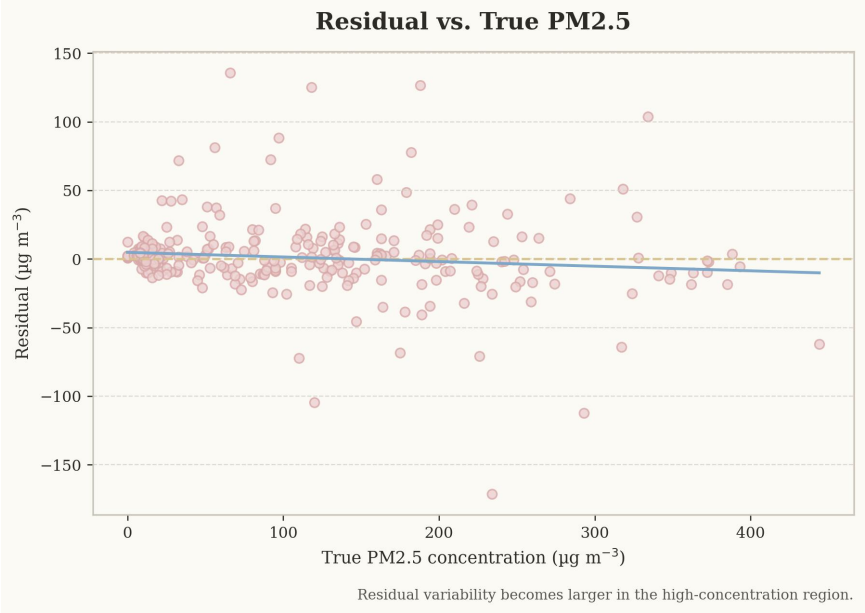

图 15 残差与真实 PM2.5 的关系

6.6 不同污染等级下的误差

为了观察预测结果在空气质量等级上的表现，实验将真实 PM2.5 按 0–35、35–75、75–115、115–150、>150 分段，统计每一段的平均绝对误差。结果见表 7。

表 7 不同 PM2.5 区间下的误差

真实 PM2.5 区间	样本数	平均绝对误差	中位绝对误差
0–35	148	5.68	3.14
35–75	35	16.83	8.60
75–115	32	18.70	12.39
115–150	36	16.60	9.99
>150	83	24.85	15.30

低浓度区间的误差较小，>150 区间的平均绝对误差最高。这个结果与残差图相互印证：模型对多数常规样本预测较稳定，但在严重污染区间误差变大。由于高污染事件往往与短时间气象变化、区域输送和污染排放条件有关，仅依靠当前数据中的变量难以完全解释。

图 16 将各 PM2.5 区间的平均绝对误差可视化。图中显示，误差随污染等级升高总体增大，特别是 >150 区间误差较明显。

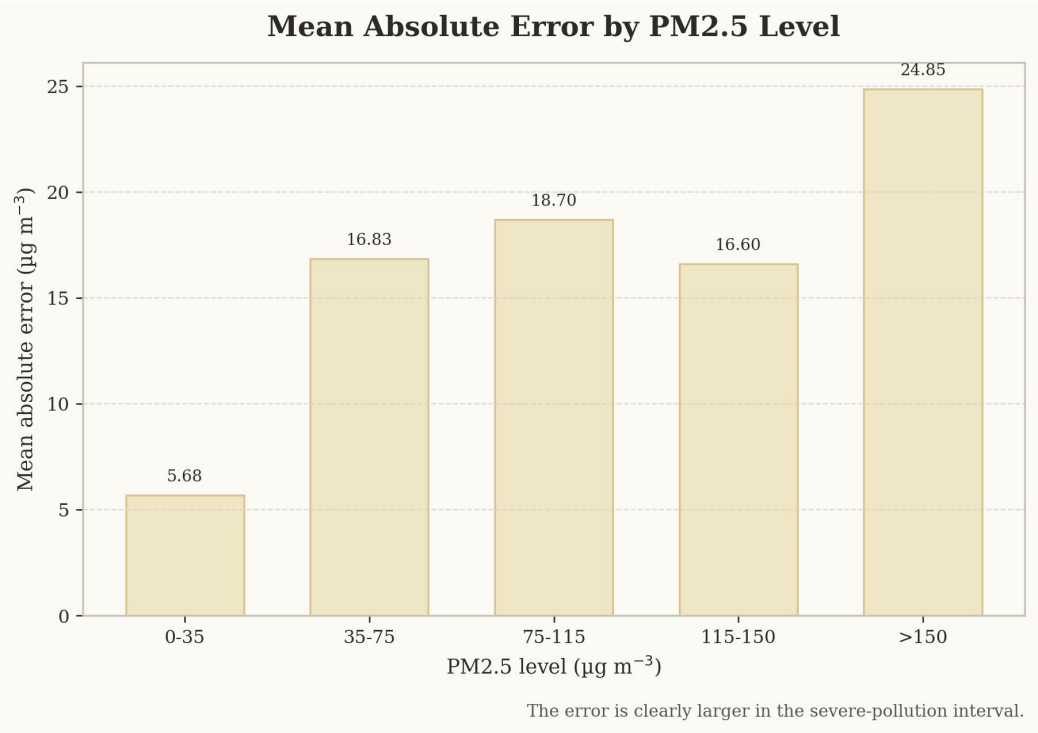

图 16 不同 PM2.5 等级下的平均绝对误差

图 17 是 PM2.5 等级混淆矩阵。对角线上的数量较多，说明模型在多数样本上能够给出相邻或正确的等级判断。错误主要集中在相邻等级之间，跨越多个等级的错误相对较少。这说明即使模型在具体数值上存在误差，预测结果仍能在一定程度上反映空气质量等级变化。

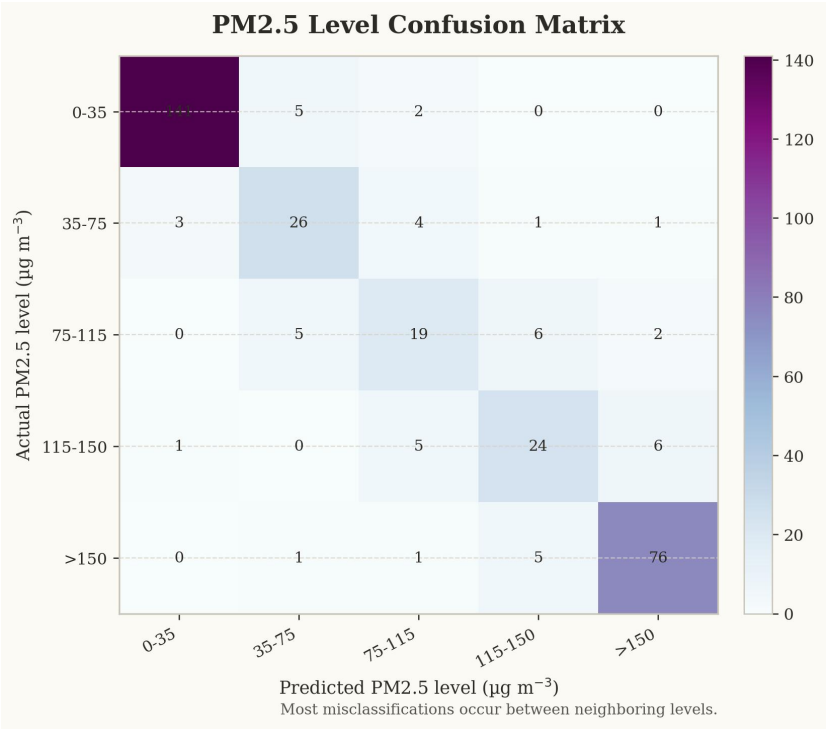

图 17 PM2.5 等级混淆矩阵

表 8 给出等级混淆矩阵的具体数值。

表 8 PM2.5 等级混淆矩阵数值

真实等级 / 预测等级	0–35	35–75	75–115	115–150	>150
0–35	141	5	2	0	0
35–75	3	26	4	1	1
75–115	0	5	19	6	2
115–150	1	0	5	24	6
>150	0	1	1	5	76

6.7 置换重要性分析

置换重要性通过随机打乱某一特征的时间顺序，观察模型 RMSE 增加量来衡量该特征对模型预测的影响。表 9 列出 RMSE 增加量较大的特征。

表 9 置换重要性结果

特征	RMSE 增加量
pollution	112.96
wnd_dir_cv	0.96
wnd_dir_NW	0.75
hour_cos	0.51
wnd_dir_SE	0.46
temp	0.38

press	0.32
wnd_dir_NE	0.04
dew	0.02
wnd_spd	0.02

pollution 的重要性远高于其他特征，说明模型主要依赖历史 PM2.5 进行下一小时预测。这一结果与特征消融实验一致。风向、小时周期、温度和气压也有一定影响，但影响幅度明显小于 pollution。rain、snow 及其二值事件特征在本次测试中的置换影响接近 0，可能与这些事件样本较少有关。

图 18 展示了置换重要性的前若干项。图中 pollution 的贡献远高于其他特征，因此在报告解释中不宜把气象变量写成主导因素。更准确的说法是：气象变量提供辅助信息，而短期预测的主要依据仍是历史 PM2.5。

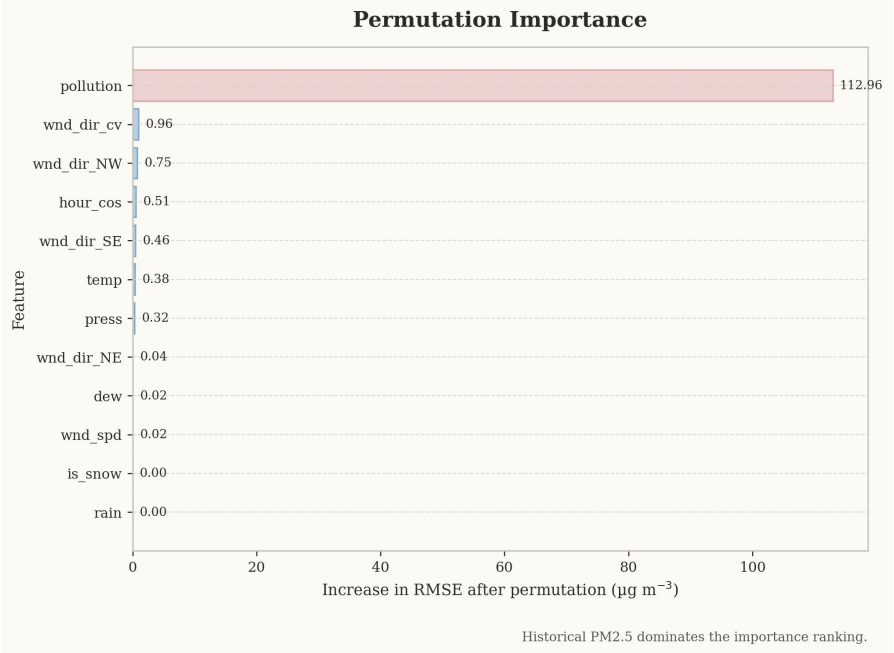

图 18 LSTM 置换重要性

7 讨论

本实验结果反映出 PM2.5 小时级预测的一个特点：短期内污染浓度具有较强连续性，因此简单的 Persistence 基线已经能够取得较高 R^2。Residual-LSTM 在 MAE 上略好于 Persistence，但 RMSE 改进有限，说明模型可以学习到部分修正信息，但并没有完全解决高峰值预测问题。HistGradientBoosting 在本次测试集中表现较好，说明当窗口特征被展平后，非线性树模型能够有效利用局部历史信息。

多变量输入并未在本次消融实验中明显优于仅使用 pollution 的输入。该结果需要谨慎解释。短期预测中，历史 PM2.5 本身包含了当前污染积累、扩散条件和其他未显式观测因素

的综合结果，因此它对下一小时预测的作用很强。气象变量的价值可能更多体现在较长预测步长、极端天气条件或更长测试区间中。本实验的测试集只有 346 条记录，结论不应过度外推。

模型在低浓度区间表现较稳定，在高浓度区间误差增大。这与数据分布和污染事件特征有关。训练集中低浓度和中等浓度样本数量更多，模型更容易学习这些区间的变化规律；高污染峰值通常变化更快，也可能受外部排放、区域输送等变量影响，而这些信息并未包含在当前数据中。

Residual-LSTM 的残差形式适合该任务，因为它把最近一小时 PM2.5 作为基准，减少了模型从零学习短期连续性的难度。但这种设计也有局限：当真实 PM2.5 发生突变时，模型可能仍然受最近一小时数值影响，预测曲线偏平滑。后续若进行多步预测或极端污染预警，可以考虑引入 Attention、外部气象预报、节假日和供暖季等变量。

8 结论

本实验围绕 PM2.5 下一小时预测任务，完成了数据预处理、滑动窗口构造、Residual-LSTM 建模、模型对比、特征消融和误差分析。实验结果显示，在本次设置下，12 小时窗口的 Residual-LSTM 测试集 MAE 为 14.04，RMSE 为 26.40，R^2 为 0.9286。该模型能够较好跟随 PM2.5 的整体变化趋势，但在高污染峰值附近误差较大。

对照实验表明，HistGradientBoosting 在本测试集上的 RMSE 低于 Residual-LSTM，说明传统非线性模型在短期预测中仍有竞争力。Persistence 基线也取得较高 R^2，反映出 PM2.5 小时级预测中的强自相关性。特征消融和置换重要性进一步说明，历史 PM2.5 是主要信息来源，气象变量和风向特征在本实验中更多起辅助作用。

从应用角度看，模型对空气质量等级的判断多数落在正确或相邻等级，但严重污染区间误差较高。若后续希望提升实用性，可以将任务扩展到多步预测，并加入更丰富的外部变量，特别是气象预报、排放活动和区域输送相关特征。

参考文献

[1] Hochreiter, S., & Schmidhuber, J. Long Short-Term Memory. Neural Computation, 1997.

[2] Kaggle: LSTM Datasets - Multivariate and Univariate Air Pollution Dataset.

[3] Scikit-learn Documentation: Ridge Regression and HistGradientBoostingRegressor.

[4] PyTorch Documentation: LSTM and neural network training utilities.