

Transformer 位置编码机制

—— 基于 Q/K 位置注入与 GQK-PI 的分析

23376044 陈科屹

摘要

本实验复现了 Transformer 编码器中的核心结构，并围绕位置编码研究其在自注意力机制中的作用。Transformer 不使用循环结构和卷积结构，模型本身不天然包含序列顺序信息。因此，位置编码不是普通的输入增强，而是序列建模中的关键机制。本实验比较了 No PE、Scalar PE、Random PE、Learned PE、Sinusoidal PE、QK-Sin、V-Sin、Layerwise-Sin 和 GQK-PI 等位置机制。

实验设置包括 order 顺序识别任务、shift 相对位置外推任务、reverse 强重排压力测试和 bag 控制任务。结果表明，在 order 任务中，No PE 和 V-Sin 接近随机水平，而 QK-Sin 和 GQK-PI 在长度 64 上分别达到 0.8326 和 0.8316 的准确率。在 shift 任务中，QK-Sin 和 GQK-PI 在长度 256 上仍保持 0.8263 和 0.8311 的 token accuracy，明显高于 Sinusoidal PE 的 0.2408 和 V-Sin 的 0.0336。Reverse 任务更难，Q/K 位置注入在训练长度附近有效，但在长度 128 和 256 上外推明显下降。实验说明，位置编码的关键作用在于参与 attention score 的计算，即影响模型“看哪里”；相比直接写入 V，位置进入 Q/K 更能支持顺序建模和相对位置外推。

一、实验目的

1.1 作业要求与研究对象

本次作业要求阅读并复现经典论文 *Attention Is All You Need*，并通过实验理解 Transformer 中某个模块的必要性。可选方向包括位置编码、Q/K/V 的必要性、残差结构、CNN 与 Transformer 对比，以及独立改进想法。本文选择位置编码作为主要研究对象，并加入一种探索性改进方法 GQK-PI。

本文不以复现原论文大规模 WMT 机器翻译结果为目标。实验重点放在 Transformer 自注意力结构和位置编码机制上，通过可控任务分析位置编码的作用。

1.2 本实验关注的问题

Transformer 去掉了 RNN 和 CNN。模型本身不再天然包含词序。位置编码

因此成为 Transformer 处理序列任务的必要补充。

本文关注的问题是：

位置编码只是输入端的附加特征，还是主要通过 Q/K 影响 attention score?

若位置主要决定模型 "看哪里"，它应更直接地作用于 Q/K 的匹配过程。若位置只是内容表示的一部分，直接加入输入或 V 中也应有效。

1.3 实验目标

本实验目标如下：

1. 复现 Transformer encoder 的核心结构，包括 self-attention、multi-head attention、FFN、residual connection 和 LayerNorm。
2. 比较不同位置机制在顺序识别、相对位置外推和强重排任务中的表现。
3. 验证 Q/K 位置注入是否优于 V-only 位置注入。
4. 设计并测试 GQK-PI 门控 Q/K 位置注入方法，观察其性能和可解释性。

二、实验原理

2.1 Transformer 自注意力结构

Transformer 的核心计算是 scaled dot-product attention：

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k}) V$$

其中， Q 和 K 决定注意力权重， V 提供被聚合的信息内容。

Multi-head attention 将输入投影到多个子空间中，并行学习不同的匹配关系。

在本实验中，模型采用 encoder-only 结构。每一层包括：

该结构保留了 Transformer encoder 的主要计算方式。

2.2 无位置编码时的置换等变性

设输入序列表示为：

$$X \in \mathbb{R}^{n \times d}$$

无位置编码时：

$$Q = XW_Q, K = XW_K, V = XW_V$$

若用置换矩阵 P 打乱输入顺序：

$$X' = PX$$

则：

$$Q' = PXW_Q = PQ$$

$$K' = PXW_K = PK$$

$$V' = PXW_V = PV$$

attention score 变为：

$$Q'K^T = (PQ)(PK)^T = PQK^TP^T$$

因此注意力输出满足：

$$\text{Attention}(PX) = P\text{Attention}(X)$$

这说明，无位置编码的 self-attention 对输入顺序具有置换等变性。它可以处理 token 集合，但不能主动区分同一组 token 的不同排列。位置编码的作用不是简单增加参数，而是打破这种顺序不可辨识性。

2.3 位置编码对 $Q/K/V$ 的影响

标准 Transformer 将 token embedding 和 position encoding 相加：

$$h_i = e_i + p_i$$

第 i 个位置对第 j 个位置的 attention score 为：

$$s_{ij} = (h_i W_Q)(h_j W_K)^T$$

展开可得：

$$s_{ij} = (e_i W_Q)(e_j W_K)^T + (e_i W_Q)(p_j W_K)^T + (p_i W_Q)(e_j W_K)^T + (p_i W_Q)(p_j W_K)^T$$

第一项是内容与内容的匹配。后三项与位置有关。

这说明位置编码会直接影响 attention score，也就是影响模型选择信息来源的方式。

因此，本实验提出一个判断：

位置编码的关键作用更接近于影响 Q/K 匹配，而不是简单写入 V 的内容表示。

2.4 GQK-PI：门控 Q/K 位置注入

基于上述分析，本文设计了 GQK-PI 方法。其思想是：位置只进入 Q/K ，不进入 V 。

对第 i 个位置，设当前层输入为 H_i ，门控后的位置向量为 $\tilde{p}_i$ ，则：

$$Q_i = H_i W_Q + \alpha_Q \tilde{p}_i U_Q$$

$$K_i = H_i W_K + \alpha_K \tilde{p}_i U_K$$

$$V_i = H_i W_V$$

其中， $\tilde{p}_i$ 由 sinusoidal 位置向量经过层、head、频段门控后得到。GQK-PI 的特点是：

1. 位置信息只进入 Q/K ；
2. V 保持内容表示；
3. 每层、每个 head 可以学习不同的位置频段权重；
4. gate heatmap 可以用于观察模型对位置频段的使用。




图 1 Transformer 中不同位置注入方式示意图

三、实验设计

3.1 模型结构与公共训练设置

实验采用统一的 Transformer encoder 设置。主要参数如下。

项目	设置
模型	Transformer encoder
层数	4
d_{model}	128
attention heads	4
d_{ff}	512
batch size	128
eval batch size	256
random seeds	0, 1, 2
训练长度	16 - 64
测试长度	16, 32, 64, 128, 256
shift 偏移量	$k = 5$

order 和 bag 任务训练 3000 steps。shift 和 reverse 任务训练 5000 steps。所有主要实验均使用 3 个随机种子，结果取平均。

3.2 位置机制对比方法

方法	代码名	说明
No PE	no_pe	不加入位置编码
Scalar PE	scalar	简单绝对标量位置编码
Random PE	random	固定随机位置向量

方法	代码名	说明
Learned PE	<code>learned</code>	可学习绝对位置编码
Sinusoidal PE	<code>sinusoidal</code>	原文 sinusoidal 位置编码
QK-Sin	<code>qk_sin</code>	sinusoidal 只注入 Q/K
V-Sin	<code>v_sin</code>	sinusoidal 只注入 V
Layerwise-Sin	<code>layerwise_sin</code>	每层重新注入 sinusoidal
GQK-PI	<code>gqk_pi</code>	门控 Q/K 位置注入

正文采用正式方法名。代码名仅用于说明实验实现和结果文件对应关系。

QK-Sin、V-Sin 和 GQK-PI 是本实验分析的重点。QK-Sin 和 V-Sin 用于判断位置更适合进入匹配过程还是内容表示；GQK-PI 用于进一步验证可门控 Q/K 位置注入的可行性。

3.3 实验任务

3.3.1 Order 任务

Order 是顺序敏感二分类任务。该任务用于判断模型是否能够区分同一组 token 的不同排列。若模型缺少有效位置信息，则容易退化到随机水平。

3.3.2 Shift 任务

Shift 是相对位置外推任务。目标形式为：

$$y_i = x_{i-k}$$

本实验设定：

$$k = 5$$

模型需要根据固定相对位移找到对应 token。该任务直接检验模型是否能学习相对位置关系。训练长度为 16–64，测试长度扩展到 128 和 256，用于观察长度外推能力。

3.3.3 Reverse 任务

Reverse 是强重排任务。目标形式为：

$$y_i = x_{L-l-i}$$

其中 L 是序列长度。与 **shift** 不同，**reverse** 不仅依赖固定偏移，还依赖全局长度和对称位置关系。因此，它作为压力测试，用于观察位置机制在强顺序重排任务中的边界。

3.3.4 Bag 任务

Bag 是顺序无关控制任务。原本设计目的是验证 **No PE** 在不依赖顺序的任务上是否具有足够容量。但本次实验中各方法在 **bag** 上均接近随机水平。因此，**bag** 只作为实验完整性记录，不作为主要正证据。




图 2 位置编码实验设计与证据链

3.4 评价指标

分类任务使用 **accuracy**:

$$\text{Accuracy} = \frac{\text{correct predictions}}{\text{all predictions}}$$

序列任务使用 **token accuracy** 和 **exact match**。

$$\text{TokAcc} = \frac{\text{correct tokens}}{\text{all tokens}}$$

$$EM = \frac{\text{fully correct sequences}}{\text{all sequences}}$$

Exact Match 对长序列非常严格。只要一个位置错误，整条序列就判错。例如，当 $\text{TokAcc}_{128} = 0.8938$ 时，若粗略假设每个位置独立正确，则整条 128 长度序列完全正确的概率约为：

$$0.8938^{128} \approx 5.8 \times 10^{-7}$$

因此，在 shift 和 reverse 的长序列外推中， EM_{128} 和 EM_{256} 为 0 并不表示模型完全失效。本文正文主要使用 TokAcc 分析外推能力，同时保留 EM_{64} 作为训练长度边界附近的严格指标。完整 EM 结果放入附录。

四、实验结果与分析

4.1 Order 任务：位置应参与 Q/K 匹配

Order 任务用于检验模型是否能识别顺序。结果见图 3。




图 3 Order 任务不同位置机制的准确率变化

长度 64 上的主要结果如下。

方法	Accuracy ₆₄
No PE	0.5000
Sinusoidal PE	0.5000
QK-Sin	0.8326
V-Sin	0.5000
Layerwise-Sin	0.5628
GQK-PI	0.8316

No PE 在 **order** 任务上为 0.5000，接近随机。说明没有位置编码时，模型不能可靠地区分顺序敏感样本。

V-Sin 同样接近随机，长度 64 上为 0.5000。这说明仅把位置写入 V ，并不能有效改变 **attention** 的匹配过程。模型仍然缺少 "应该看哪里" 的位置信号。

QK-Sin 在长度 64 上达到 0.8326，GQK-PI 达到 0.8316。二者明显高于 No PE 和 V-Sin。该结果支持前面的理论判断：位置信息进入 Q/K 后可以直接影响 **attention score**，从而改善顺序识别。

Sinusoidal PE 在本任务中没有表现出优势，长度 64 上仍为 0.5000。本文不据此得出 "Sinusoidal PE 无效" 的一般结论。更准确的说法是：在本实验的 **order** 设置和当前实现下，标准输入加法 Sinusoidal PE 没有有效改变该任务中的匹配关系； Q/K 侧注入更直接。

4.2 Shift 任务：相对位置外推

Shift 是本文的主实验。该任务要求模型根据固定偏移 $k = 5$ 找到对应 token。它直接检验位置机制对相对位置关系的建模能力。




图 4 Shift 任务 token accuracy 随长度变化

正文主表报告 TokAcc、EM₆₄ 和 token 外推下降量。定义：

$$\Delta_{\text{Tok}} = \text{TokAcc}_{64} - \text{TokAcc}_{256}$$

结果如下。

方法	TokAcc ₆₄	TokAcc ₁₂₈	TokAcc ₂₅₆	EM ₆₄	Δ _{Tok}
No PE	0.0853	0.0681	0.0564	0.0000	0.0289
Scalar PE	0.0852	0.0680	0.0563	0.0000	0.0289
Random PE	0.0853	0.0682	0.0564	0.0000	0.0289
Learned PE	0.1416	0.0899	0.0661	0.0000	0.0755
Sinusoidal PE	0.9071	0.4569	0.2408	0.0010	0.6663
QK-Sin	1.0000	0.8938	0.8263	1.0000	0.1737
V-Sin	0.0902	0.0446	0.0336	0.0000	0.0566
Layerwise-Sin	1.0000	0.8011	0.6237	1.0000	0.3763
GQK-PI	1.0000	0.8705	0.8311	1.0000	0.1689

No PE、Scalar PE 和 Random PE 在 shift 任务中均较弱。长度 256 上 token accuracy 约为 0.056。Learned PE 略高于它们，但长度 256 上仅为 0.0661。说明简单绝对位置、固定随机位置和可学习绝对位置都没有形成有效外推能力。

Sinusoidal PE 明显优于 Learned PE、Scalar PE 和 Random PE。其长度 64 上 TokAcc₆₄ 为 0.9071, 长度 256 上 TokAcc₂₅₆ 为 0.2408。这说明结构化 sinusoidal 位置编码确实提供了有效的位置关系信息。但它在长外推长度上下降明显, Δ_{Tok} 为 0.6663。

QK-Sin 的表现最稳定。长度 64 上 $\text{TokAcc}_{64} = 1.0000$ ，长度 128 上为 0.8938，长度 256 上仍为 0.8263。GQK-PI 与 QK-Sin 接近，长度 256 上为 0.8311，略高于 QK-Sin。二者的 Δ_{Tok} 分别为 0.1737 和 0.1689，明显低于 Sinusoidal PE。

V-Sin 明显较弱。长度 256 上 $\text{TokAcc}_{256} = 0.0336$ ，低于 No PE。这说明仅在 V 中加入位置不能帮助模型选择正确的相对位置。位置必须影响 attention score，才能有效解决 shift 任务。

Shift 结果是本文最重要的证据。它说明：位置编码的有效性不仅取决于编码形式，也取决于注入位置。 Q/K 位置注入明显优于 V-only 位置注入和标准输入加法位置编码。

4.3 Reverse 任务：强重排压力测试

Reverse 任务要求输出反转序列。该任务比 **shift** 更难，因为目标位置依赖全局序列长度，而不是固定偏移。




图 5 Reverse 任务 token accuracy 随长度变化

正文主表同样报告 TokAcc 和 EM_{64} 。完整 EM_{128} 、 EM_{256} 放入附录。

方法	TokAcc ₆₄	TokAcc ₁₂₈	TokAcc ₂₅₆	EM ₆₄
No PE	0.0859	0.0683	0.0569	0.0000
Scalar PE	0.0859	0.0684	0.0569	0.0000
Random PE	0.0858	0.0683	0.0570	0.0000
Learned PE	0.0859	0.0683	0.0569	0.0000
Sinusoidal PE	0.0858	0.0682	0.0569	0.0000
QK-Sin	0.9987	0.0381	0.0354	0.9473
V-Sin	0.0856	0.0668	0.0544	0.0000
Layerwise-Sin	1.0000	0.0328	0.0354	1.0000
GQK-PI	0.9727	0.0398	0.0363	0.3322

在长度 64 上，QK-Sin、Layerwise-Sin 和 GQK-PI 明显优于其他方法。QK-Sin 的 EM_{64} 为 0.9473，TokAcc₆₄ 为 0.9987；Layerwise-Sin 的 EM_{64} 为 1.0000；GQK-PI 的 TokAcc₆₄ 为 0.9727，但 EM_{64} 为 0.3322。

这说明 Q/K 位置注入和逐层注入能改善训练长度附近的强顺序重排能力。

但在长度 128 和 256 上，所有方法都明显下降。QK-Sin 在长度 256 上 TokAcc₂₅₆ = 0.0354，GQK-PI 为 0.0363，均接近随机。Reverse 结果说明，shift 中的相对位置外推能力不能直接推广到强重排任务。固定偏移和全局反转的难度不同。

因此，reverse 不作为本文的主要正面结果，而作为压力测试。它表明： Q/K 位置注入有助于训练长度附近的顺序重排，但不能保证复杂重排任务的长度外推。

4.4 GQK-PI 门控分析

GQK-PI 在 shift 任务中与 QK-Sin 接近，并在长度 256 上略高于 QK-Sin：

$$\text{TokAcc}_{256}(\text{GQK-PI}) = 0.8311$$

$$\text{TokAcc}_{256}(\text{QK-Sin}) = 0.8263$$

二者均明显高于 Sinusoidal PE 的 0.2408 和 V-Sin 的 0.0336。




图 6 GQK-PI 平均 gate 热力图

Gate heatmap 显示，不同层、不同 head 对位置频段的使用强度并不完全相同。这说明 GQK-PI 不只是固定加入位置向量，而是允许模型选择不同尺度的位置特征。

GQK-PI 的意义主要有两点：

1. 它验证了 " 位置主要进入 Q/K 匹配过程 " 的思路；
2. 它提供了一个可解释的 gate 观察窗口。

但本文不声称 GQK-PI 全面优于 QK-Sin。Reverse 任务中，GQK-PI 的 EM_{64} 低于 QK-Sin，长度 128 和 256 上也没有形成有效外推。因此，GQK-PI 更适合作为一种可行的探索性改进，而不是最终最优方法。

4.5 Bag 控制实验与异常说明

Bag 任务原本用于构造顺序无关控制。若该任务成功，No PE 应该也能取得较好结果，从而证明 No PE 在 order 中失败不是容量不足，而是顺序不可识别。




图 7 Bag 控制任务准确率变化。

但本次实验中，各方法在 **bag** 上均接近随机。长度 64 上主要结果如下。

方法	Accuracy ₆₄
No PE	0.4977
Sinusoidal PE	0.4977
QK-Sin	0.4977
V-Sin	0.4977
GQK-PI	0.4977

该结果说明 **bag** 任务设置或训练目标没有形成有效正控制。因此，**bag** 不用于支撑主结论，只作为实验局限记录。本文关于位置编码的主要结论来自 **order**、**shift** 和 **reverse**。

五、讨论

5.1 位置编码的核心作用

实验结果显示，位置编码的核心作用不是简单增加输入特征。

在 order 任务中，标准输入加法 Sinusoidal PE 没有优于 No PE，而 QK-Sin 和 GQK-PI 明显提升。在 shift 任务中，QK-Sin 和 GQK-PI 在长度 256 上仍保持较高 token accuracy，而 V-Sin 基本失效。

这说明位置编码更关键的作用是参与 attention score 的计算。换言之，位置帮助模型判断 "应该看哪个位置"。

5.2 Q/K 与 V 的功能分工

Q/K 决定匹配关系， V 决定被读取内容。

如果只将位置注入 V ，模型虽然在内容表示中带有位置，但 attention 权重本身没有获得足够的位置匹配能力。

实验中，V-Sin 在 order 上接近随机，在 shift 上长度 256 的 token accuracy 仅为 0.0336。QK-Sin 在相同长度上达到 0.8263。这一差异说明位置进入 Q/K 比进入 V 更有效。

5.3 GQK-PI 的意义

GQK-PI 保持了 Q/K 位置注入的核心思想，并加入可学习 gate。它在 shift 上与 QK-Sin 接近，在长度 256 上略高于 QK-Sin。

它的主要价值不是单纯提高指标，而是提供了一种更可解释的位置注入形式。通过 gate heatmap，可以观察不同层、不同 head 对位置频段的选择。

但 GQK-PI 在 reverse 上没有解决长长度外推问题。该结果说明，门控 Q/K 位置注入可以增强某些相对位置任务，但并不能自动解决所有顺序重排问题。

5.4 实验限制

本实验存在以下限制。

第一，实验使用合成任务，不等同于大规模机器翻译。本文复现的是 Transformer encoder 结构和位置编码机制，不复现原论文 WMT 翻译结果。

第二，bag 控制实验没有形成有效正控制。所有方法在该任务上接近随机，因此不能用 bag 证明 No PE 在非顺序任务中容量充足。

第三，Exact Match 在长序列上过于严格。Shift 中 QK-Sin 和 GQK-PI 在长度 128、256 上 Exact Match 为 0，但 token accuracy 仍较高。结果分析需要结合

两类指标。

第四，reverse 外推整体较弱。 Q/K 位置注入在长度 64 附近有效，但长度 128 和 256 上明显退化。这说明强重排任务的长度外推仍未解决。

六、结论

本实验围绕 Transformer 位置编码机制进行了复现和分析。主要结论如下。

1. 无位置编码的 self-attention 对输入顺序具有置换等变性，因此在顺序敏感任务中容易退化。Order 实验中，No PE 在长度 64 上准确率为 0.5000，接近随机。

2. 位置信息进入 Q/K 比进入 V 更有效。Order 任务中，QK-Sin 的 Accuracy_{64} 为 0.8326，V-Sin 为 0.5000；shift 任务中，QK-Sin 的 TokAcc_{256} 为 0.8263，V-Sin 为 0.0336。

3. Sinusoidal PE 能够提供一定位置结构，但在本实验中不如 Q/K 侧注入稳定。Shift 任务中，Sinusoidal PE 的 TokAcc_{256} 为 0.2408，而 QK-Sin 和 GQK-PI 分别为 0.8263 和 0.8311。

4. GQK-PI 是一种可行的探索性改进。它在 shift 任务中接近或略优于 QK-Sin，并通过 gate heatmap 提供了一定可解释性。但 reverse 结果显示，它不能保证复杂重排任务的长长度外推。


5. Reverse 任务表明，位置注入能改善训练长度附近的顺序重排，但不能单独解决强重排外推问题。位置编码是 Transformer 顺序建模的必要机制，但其形式和注入位置都会影响最终效果。

因此，位置编码不应只被理解为输入 embedding 的附加项。更合理的理解是：位置编码为 attention matching 提供结构化信号，其注入位置会显著影响模型的顺序建模能力。


参考文献

- [1] Vaswani, A., Shazeer, N., Parmar, N., et al. Attention Is All You Need. Advances in Neural Information Processing Systems, 2017.


附录 A：主要结果补充图




附图 A1 Shift 任务完整 Exact Match 曲线。




附图 A2 Shift 任务核心方法 Exact Match 曲线。




附图 A3 Reverse 任务完整 Exact Match 曲线。



附图 A4 Reverse 任务核心方法 Exact Match 曲线。




附图 A5 Order 任务训练损失曲线。



附图 A6 Bag 任务训练损失曲线。


附录 B：位置编码与 gate 热力图

Representative Positional Encoding Heatmaps




附图 B1 代表性位置编码热力图。

Order GQK-PI Gate Heatmaps




附图 B2 Order 任务 GQK-PI 各 seed、各层 gate 热力图。

Shift GQK-PI Gate Heatmaps



附图 B3 Shift 任务 GQK-PI 各 seed、各层 gate 热力图。

Reverse GQK-PI Gate Heatmaps



附图 B4 Reverse 任务 GQK-PI 各 seed、各层 gate 热力图。

附录 C：表格说明

完整 CSV 与 LaTeX 表格位于实验打包目录中，包括 `mechanism_main_table`、`shift_main_table`、`reverse_main_table`、`shift_gap_table` 和 `reverse_gap_table`。正文只保留最能说明结论的指标；完整 EM@128 和 EM@256 放在附录表格文件中。